

Classificação – Conceitos Básicos e Árvore de Decisão

Aula 02 – Inteligência Computacional

Eduardo Corrêa Gonçalves

12/08/2026

Sumário

Introdução

- O que é classificação?
- Exemplos de aplicações

Como criar um classificador?

Árvore de Decisão

- O que é Árvore de Decisão? Como é gerada?
- Algoritmo CART – exemplo passo a passo
- Comentários adicionais
- Prós e contras das Árvores de Decisão


Introdução (1/6)

Classificação

Processo em que um **modelo** treinado (criado) por um algoritmo é utilizado para determinar a **classe** de um **objeto** de maneira automática.


Ex.: Classificador de Sentimentos

Recebe um texto contendo uma opinião como entrada (sobre um produto, restaurante, filme etc.) e, como saída, classifica a opinião como “**Positiva**” ou “**Negativa**”



Introdução (2/6)

Classificação




Introdução (3/6)

Exemplos de Aplicações

Identificação de fraudes

Objeto: transação de cartão de crédito


classes possíveis: “normal” ou “fraudulenta”



Identificação de Spam

Objeto: e-mail

classes possíveis: “normal” ou “spam”



➡ **SPAM**


Introdução (4/6)

Exemplos de Aplicações

Classificação do risco de crédito

Objeto: cliente de um banco (descrito por: idade, renda, estado civil, profissão etc.)

classes possíveis: risco “baixo”, “médio” ou “alto”



risco alto

Introdução (5/6)

Exemplos de Aplicações

Classificação de cenas

Objeto: fotografia de um cenário da natureza (pode ser foto de satélite ou não)

classes possíveis: montanha, árvore, rio, praia etc.



montanhas + árvores

*Nessa aplicação, objeto
pode ser classificado
com mais de 1 classe!*

Introdução (6/6)

São inúmeras aplicações práticas... Veja mais duas ...

Identificação de discurso de ódio

objeto: comentário na Internet

classes: “sim” (texto é ofensivo) x “não” (não é)

Classificação de risco de doença cardiovascular

objeto: pessoa (descrita por: gênero, idade, peso, altura, pressão sistólica, colesterol, se é fumante ou não)

classes: “baixo”, “médio” e “alto”.

muitas outras...

Como criar um classificador? (1/6)

Você precisa de “apenas” duas coisas:

1. Um bom **algoritmo de classificação**.

Exemplos: CART, Regressão Logística, Rede Neural Feed Forward, SVM etc.

2. Uma boa **base de dados de treinamento**.

Esta base deve conter **objetos classificados**, de acordo com **classes pré-definidas**.

Como criar um classificador? (2/6)

- **Exemplo – base de dados de treinamento**

- **Objetivo:** criar um classificador para determinar se foto é de “adulto” ou “criança”

X	Y
x_1 : 	y_1 : Adulto
x_2 : 	y_2 : Criança
x_3 : 	y_3 : Criança
x_4 : 	y_4 : Adulto
...	...
x_N : 	y_N : Adulto

Como criar um classificador? (3/6)

- **Exemplo – base de dados de treinamento**

- **Objetivo:** criar um classificador para determinar se foto é de “adulto” ou “criança”

- **X é um conjunto de atributos preditivos.**

- São os atributos (variáveis) que contêm as características (*features*) dos objetos.
- Em geral, são **atributos numéricos** (alguns algoritmos aceitam categóricos).

X	Y
x_1 : 	y_1 : Adulto
x_2 : 	y_2 : Criança
x_3 : 	y_3 : Criança
x_4 : 	y_4 : Adulto
...	...
x_N : 	y_N : Adulto

Como criar um classificador? (4/6)

• Exemplo – base de dados de treinamento

- **Objetivo:** criar um classificador para determinar se foto é de “adulto” ou “criança”

• **X** é um conjunto de atributos preditivos.

- São os atributos (variáveis) que contêm as características (*features*) dos objetos.
- Em geral, são atributos numéricos (alguns algoritmos aceitam categóricos).

X	Y
x_1 : 	y_1 : Adulto
x_2 : 	y_2 : Criança
x_3 : 	y_3 : Criança
x_4 : 	y_4 : Adulto
...	...
x_N : 	y_N : Adulto

• **Y** é o atributo classe.

- Atributo **alvo** da classificação.
- Sempre um atributo categórico, que pode assumir 2 ou mais valores.
- Neste exemplo, cada $y_i \in \{\text{Adulto}, \text{Criança}\}$
- “Adulto” e “Criança” são as **classes** ou **rótulos de classe**.

Como criar um classificador? (5/6)

- O **algoritmo de classificação** vai **aprender** com a base de treinamento.
- Ao final do aprendizado criará um **modelo**, denominado “**modelo de classificação**” ou “**classificador**”.
 - Você pode imaginar que o classificador é como uma função de mapeamento **$y = f(x)$** .
 - Essa função será utilizada para classificar **novos objetos** (objetos cuja classe é desconhecida).
 - **Exemplo:** $f(\text{) = \text{Criança}$

X	Y
x_1 : 	y_1 : Adulto
x_2 : 	y_2 : Criança
x_3 : 	y_3 : Criança
x_4 : 	y_4 : Adulto
...	...
x_N : 	y_N : Adulto

Como criar um classificador? (6/6)


- Antes de prosseguirmos... uma informação importante sobre classificação de imagens

- Na prática, uma imagem (dado não estruturado) **precisa ser convertida** para o formato estruturado para que o treinamento possa ser feito.
 - Isso é: ser transformada em um **vetor ou matriz numérica**.
 - **Por exemplo:** cada imagem pode ser convertida para uma matriz RGB, que é uma das possíveis formas numéricas para representação de imagens.
- O mesmo ocorre com textos (veremos em aulas futuras).

X	Y
x_1 : 	y_1 : Adulto
x_2 : 	y_2 : Criança
x_3 : 	y_3 : Criança
x_4 : 	y_4 : Adulto
...	...
x_N : 	y_N : Adulto

O que é Árvore de Decisão ? (1/7)

- Modelos Caixa Preta
 - Muitos algoritmos de classificação modernos constroem modelos **caixa preta**.
 - Projetados para maximizar o desempenho preditivo (acertar muitas classificações).
 - Não se preocupam em fornecer explicações sobre as razões de suas decisões (motivo da classificação).



O que é Árvore de Decisão ? (2/7)

- **Modelos Interpretáveis**

- Para muitas aplicações, isso é ok.
 - **Ex.:** classif. de spam, classif. de cenas.



- Porém, por questões **legais**, **éticas** e de **transparência**, modelos caixa preta não podem ser utilizados em todos os problemas.
 - **Ex.:** na **administração pública**, há aplicações que exigem a utilização de **modelos interpretáveis**.
 - São os modelos de classificação que possuem a habilidade de “explicar” suas decisões / previsões.
 - Isso pode ser feito, por exemplo, apresentando regras do tipo:



SE <condição> ENTÃO <rótulo de classe>

O que é Árvore de Decisão ? (3/7)

- **Árvore de Decisão (AD)** é a técnica (algoritmo) mais conhecida e utilizada para o aprendizado de classificadores interpretáveis.
- **Exemplo:** AD que classifica um cliente como “cliente de carro nacional” ou “cliente de carro importado” em função de sua “idade” e “renda”.

Base de treinamento

Idade	Renda	Aluga Carro Importado?
38	Média	Não
41	Média	Sim
45	Alta	Sim
38	Baixa	Não
29	Média	Não
55	Média	Sim
18	Baixa	Não
50	Alta	Sim




O que é Árvore de Decisão ? (4/7)

• Estrutura de uma AD

- Uma AD é uma estrutura gráfica (e intuitiva), que representa um conjunto de regras de classificação.

• Características


- A **raiz** está no **topo** e as folhas na parte inferior. Sendo assim, a raiz dessa AD é o atributo “**Renda**”.
- Cada **nó interno** é um teste sobre um atributo preditivo.
- Uma **ramificação** partindo de um nó interno, representa um resultado para o teste (ex.: **Renda = “Alta”**).
- Uma **folha** da árvore representa um rótulo de classe.



O que é Árvore de Decisão ? (5/7)

• Processo de Classificação

- Um novo objeto é classificado seguindo um **caminho** na árvore da **raiz** até a **folha**.
- **Ex.:** *novoObj* = (Cliente="George", Renda="Média", Idade = 28)



Classe predita = "Não"


Ou seja, a AD **prevê** que **George não vai** alugar um carro importado.

O que é Árvore de Decisão ? (6/7)

• Regras de Classificação

- Uma AD é composta por um conjunto de **regras de classificação**.
 - Existe um único caminho até cada folha e este caminho representa a regra!
- Na AD existem **4 folhas**, representando **4 regras**:

- (Renda="Alta") $\Rightarrow$ Sim
- (Renda="Média") & (Idade ≤ 40) $\Rightarrow$ Não
- (Renda="Média") & (Idade > 40) $\Rightarrow$ Sim
- (Renda="Baixa") $\Rightarrow$ Não





O que é Árvore de Decisão ? (7/7)

- **Confiança**

- Em nosso exemplo, todas regras possuem **confiança de 100%**.
 - Ou seja: todas as observações de treinamento são classificadas corretamente.
 - Na prática, isso dificilmente ocorre.


Base de treinamento

<i>Idade</i>	<i>Renda</i>	<i>Aluga Carro Importado?</i>
38	Média	Não
41	Média	Sim
45	Alta	Sim
38	Baixa	Não
29	Média	Não
55	Média	Sim
18	Baixa	Não
50	Alta	Sim




Como gerar uma Árvore de Decisão ? (1/3)

- Ideia básica:
 - Uma AD é composta por uma **série de questões**.
 - A resposta da primeira determina a questão seguinte, e assim sucessivamente até que um nó folha seja alcançado.
 - Sendo assim, caso as **questões** sejam **bem formuladas** (na melhor ordem possível), um pequeno número delas será suficiente para classificar corretamente um objeto.
 - Portanto, precisamos de uma boa estratégia p/ escolher os atributos que ficarão mais próximos da raiz.
 - Eles são os atributos inicialmente avaliados para determinar a classe a qual um objeto pertence.




Como gerar uma Árvore de Decisão ? (2/3)

- **Medida de Diversidade**
- Os algoritmos de AD trabalham por etapas, particionando o BD de treino.
 - A cada etapa, aplicam uma **medida de diversidade** sobre os atributos preditivos.
 - O atributo que produz nós mais **puros** será selecionado para entrar na árvore.
 - **Mais puro significa:** capaz de separar os objetos da base de treino em grupos onde um único rótulo de classe predomine. Ou seja: capaz de reduzir ao máximo a diversidade dos objetos de treino.



(A) Partições Impuras
Má divisão!



(B) Partições Puras
Boa divisão!

Como gerar uma Árvore de Decisão ? (3/3)

- Algoritmo **CART**

- É um dos mais famosos algoritmos para gerar ADs (está implementado na *scikit-learn*, pacote Python usado em nosso curso).
- Utiliza o **índice de Gini** para computar a pureza das partições geradas por um atributo.
 - Fórmula abaixo.
 - Considere que m é o número de classes e p_i é a probabilidade de um objeto t pertencer à classe y_i no conjunto de dados D .

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2$$

CART – exemplo passo a passo (1/9)

- DESCRIÇÃO DO EXEMPLO:

- O BD de treinamento ao lado possui dados de 11 pessoas analfabetas.
- Utilizando o algoritmo CART, vamos treinar um classificador para:
 - inferir se uma pessoa analfabeta tem por ocupação prestar serviços domésticos*, considerando sua idade, uf e sexo.
 - Ou seja: “**idade**”, “**UF**” e “**sexo**” formarão nosso **conjunto X** (são as **features** ou **atributos preditivos**)
 - “**trabalho_doméstico**” é a nossa **variável Y (classe)**

idade	UF	sexo	trabalho_doméstico (classe)
≤ 60	MG	M	Não
> 60	SP	F	Sim
> 60	MG	F	Sim
≤ 60	SP	M	Não
≤ 60	SP	F	Não
> 60	MG	F	Sim
≤ 60	SP	M	Não
> 60	MG	M	Não
≤ 60	MG	F	Sim
> 60	SP	F	Sim
≤ 60	MG	F	Não

* Baseado em um exemplo real, identificado na Pesquisa Mensal de Empregos do IBGE

CART – exemplo passo a passo (2/9)

• PASSO 1: escolher o nó raiz

- Na primeira rodada do CART, haverá a decisão sobre qual dos três atributos preditivos entrará como nó raiz da árvore.
- A decisão ocorre em função do resultado do cálculo do índice de Gini considerando toda a base de dados, conforme mostrado a seguir.

* “idade”:

$$(\leq 60) : (> 60) = 6/11 \times (1 - (5/6)^2 - (1/6)^2) + 5/11 \times (1 - (1/5)^2 - (4/5)^2) = 0,30$$

* “UF”:

$$(MG) : (SP) = 6/11 \times (1 - (3/6)^2 - (3/6)^2) + 5/11 \times (1 - (3/5)^2 - (2/5)^2) = 0,49$$

* “sexo”:

$$(F) : (M) = 7/11 \times (1 - (2/7)^2 - (5/7)^2) + 4/11 \times (1 - (4/4)^2 - (0/4)^2) = \underline{0,26}$$

CART – exemplo passo a passo (3/9)

- **PASSO 1: escolher o nó raiz - Como os cálculos foram feitos????**
 - Ao definir partições, o CART sempre realiza **divisões binárias**, ou seja, de cada nó interno sempre serão feitos dois testes que resultam na geração de **duas partições**.
 - Então, para cada atributo A candidato a entrar como nó da AD, o CART realiza a **soma ponderada da impureza** de cada uma das duas partições resultantes.
 - Isto é feito com o uso da fórmula a seguir, em que D1 e D2 são as duas partições geradas pela divisão binária:

$$Gini_A(D) = \frac{|D1|}{|D|} Gini(D1) + \frac{|D2|}{|D|} Gini(D2)$$

CART – exemplo passo a passo (4/9)

- Ex.: o atributo “**sexo**” gera a divisão (sexo= “F”) e (sexo = “M”).
 - $IG(\text{sexo}) \rightarrow (F) : (M) = \frac{7}{11} \times (1 - (\frac{2}{7})^2 - (\frac{5}{7})^2) + \frac{4}{11} \times (1 - (\frac{4}{4})^2 - (\frac{0}{4})^2) = \underline{0,26}$
- 1ª parte** do cálculo (em verde, antes do sinal de adição): refere-se ao cálculo da impureza da partição gerada por (sexo = “F”).
 - $7/11$ = das 11 pessoas da base, 7 são do sexo feminino.
 - $2/7$ = 2 dessas 7 mulheres são da classe “Não”
 - $5/7$ = 5 das 7 mulheres são da classe “Sim”.
- 2ª parte** do cálculo (em vermelho, depois do sinal de adição). Refere-se à impureza da partição gerada por (sexo = “M”).

$$Gini_A(D) = \frac{|D1|}{|D|} Gini(D1) + \frac{|D2|}{|D|} Gini(D2)$$

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2$$


idade	UF	sexo	trabalho_doméstico (classe)
≤ 60	MG	M	Não
> 60	SP	F	Sim
> 60	MG	F	Sim
≤ 60	SP	M	Não
≤ 60	SP	F	Não
> 60	MG	F	Sim
≤ 60	SP	M	Não
> 60	MG	M	Não
≤ 60	MG	F	Sim
> 60	SP	F	Sim
≤ 60	MG	F	Não

CART – exemplo passo a passo (5/9)

• PASSO 2: inserir o atributo escolhido na raiz da árvore

- Veja como ficam as partições da base de treinamento após o particionamento pelo atributo “sexo” (atributo selecionado).
- A partição definida por (sexo = “F”) é quase pura, pois temos 2 objetos da classe “Não” e 5 da classe “Sim”.
- Já a partição gerada por (sexo = “M”) é completamente pura.
 - Não precisaremos fazer mais nada com essa partição.
- A árvore de decisão parcial, definida em função do atributo “sexo” e as 2 partições geradas (“F” e “M”) é:

sexo	
F	M
>60, SP, F, Sim	≤ 60, MG, M, Não
>60, MG, F, Sim	≤ 60, SP, M, Não
≤ 60, SP, F, Não	≤ 60, SP, M, Não
>60, MG, F, Sim	>60, MG, M, Não
≤ 60, MG, F, Sim	
>60, SP, F, Sim	
≤ 60, MG, F, Não	



CART – exemplo passo a passo (6/9)

- **DEMAIS PASSOS:** repetir o processo para as partições restantes
 - Não precisamos fazer mais nada com os dados da partição (sexo = “M”).
 - Porém, ainda podemos investigar “idade” e “UF” para identificar qual é capaz de gerar uma boa divisão para os dados da partição (sexo = “F”).
 - Basta usar novamente o índice de Gini, porém desta vez considerando apenas as 7 observações referentes à partição (sexo = “F”).

* “idade”:

$$(\leq 60) : (> 60) = \frac{3}{7} \times (1 - (\frac{2}{3})^2 - (\frac{1}{3})^2) + \frac{4}{7} \times (1 - (\frac{0}{4})^2 - (\frac{4}{4})^2) = \underline{0,19}$$

* “UF”:

$$(MG) : (SP) = \frac{4}{7} \times (1 - (\frac{1}{4})^2 - (\frac{3}{4})^2) + \frac{3}{7} \times (1 - (\frac{1}{3})^2 - (\frac{2}{3})^2) = 0,40$$

sexo	
F	M
>60, SP, F, Sim	≤ 60, MG, M, Não
>60, MG, F, Sim	≤ 60, SP, M, Não
≤ 60, SP, F, Não	≤ 60, SP, M, Não
>60, MG, F, Sim	>60, MG, M, Não
≤ 60, MG, F, Sim	<i>Resolvido!</i>
>60, SP, F, Sim	
≤ 60, MG, F, Não	

CART – exemplo passo a passo (7/9)

- **DEMAIS PASSOS:**
repetir o processo para as partições restantes
 - O atributo “idade” é escolhido para particionar o subconjunto de dados definido pela partição (sexo = “F”).
 - A figura ao lado mostra os novos particionamentos por ele gerados.

sexo		
F		M
>60, SP, F, Sim >60, MG, F, Sim ≤ 60, SP, F, Não >60, MG, F, Sim ≤ 60, MG, F, Sim >60, SP, F, Sim ≤ 60, MG, F, Não		≤ 60, MG, M, Não ≤ 60, SP, M, Não ≤ 60, SP, M, Não >60, MG, M, Não
idade		
≤ 60	>60	
≤ 60, SP, F, Não ≤ 60, MG, F, Sim ≤ 60, MG, F, Não	>60, SP, F, Sim >60, MG, F, Sim >60, MG, F, Sim >60, SP, F, Sim	

CART – exemplo passo a passo (8/9)

• DEMAIS PASSOS: repetir o processo para as partições restantes

- A partição (**sexo = “F” & idade > 60**) é pura (todos da classe “Sim”).
- A partição (**sexo = “F” & idade ≤ 60**) não ficou pura (2 “Não”, 1 “Sim”).
 - No entanto, ela tem um número muito reduzido de objetos.
 - O CART poderá considerar que não vale mais a pena tentar dividi-la. Definirá uma folha “Não” (classe majoritária) e finalizar o modelo.


sexo		
F		M
>60, SP, F, Sim >60, MG, F, Sim ≤ 60, SP, F, Não >60, MG, F, Sim ≤ 60, MG, F, Sim >60, SP, F, Sim ≤ 60, MG, F, Não		≤ 60, MG, M, Não ≤ 60, SP, M, Não ≤ 60, SP, M, Não >60, MG, M, Não
idade		
≤ 60	>60	
≤ 60, SP, F, Não ≤ 60, MG, F, Sim ≤ 60, MG, F, Não	>60, SP, F, Sim >60, MG, F, Sim >60, MG, F, Sim >60, SP, F, Sim	

CART – exemplo passo a passo (9/9)

• Árvore de Decisão Gerada

sexo		
F		M
>60, SP, F, Sim >60, MG, F, Sim ≤ 60, SP, F, Não >60, MG, F, Sim ≤ 60, MG, F, Sim >60, SP, F, Sim ≤ 60, MG, F, Não		≤ 60, MG, M, Não ≤ 60, SP, M, Não ≤ 60, SP, M, Não >60, MG, M, Não
idade		
≤ 60	>60	
≤ 60, SP, F, Não ≤ 60, MG, F, Sim ≤ 60, MG, F, Não	>60, SP, F, Sim >60, MG, F, Sim >60, MG, F, Sim >60, SP, F, Sim	

Veja que o atributo “uf” não entrou no modelo, pois não gerou nós mais puros em nenhuma etapa (portanto, nunca foi selecionado)



Prós, Contrás e Info. Complementares (1/7)

- **Principais Vantagens das ADs**

- Modelo completamente interpretável.
- Algoritmo simples (em comparação com redes neurais...)
- Treinamento rápido.

- **Principais Desvantagens**

- Nem sempre alcança a eficácia obtida por outras técnicas
 - Um dos motivos é porque a cada etapa, o treinamento se preocupa em resolver o problema do “momento” (a partição que ele está cuidando) sem pensar muito no futuro (no problema como um todo ou nas relações entre os atributos).
- Desempenho costuma ser ruim com dados não estruturados.

Prós, Contras e Info. Complementares (2/7)


- **Como tratar atributos categóricos com mais de 2 categorias?**
 - O CART consegue gerar apenas árvores binárias.
 - **PROBLEMA:** e se existir um atributo preditivo com mais de dois valores, como por exemplo “**cor**” com os valores {“**amarela**”, “**branca**”, “**preta**”}?
 - **SOLUÇÃO:** Neste caso, o CART avaliará todas as divisões binárias possíveis, que são:
 - (**amarela**) : (**branca, preta**)
 - (**branca**) : (**amarela, preta**)
 - (**preta**) : (**amarela, branca**)

Prós, Contrás e Info. Complementares (3/7)

- **Como tratar atributos contínuos?**
 - Dado um atributo contínuo A , o CART usa os 2 passos a seguir para obter o melhor ponto de divisão:
 1. Ordenar os valores de A de maneira ascendente
 2. Testar todas as possibilidades considerando os pontos médios entre cada par de valor.
 - **Ex.:** salário com 4 valores distintos na base: 1.500, 2000, 4000 e 10.000.
 - 3 possíveis divisões p/ avaliar:
 - $(\leq 1750) : (> 1750)$ (*1.750 é o ponto médio entre 1.500 e 2.000*)
 - $(\leq 3000) : (> 3000)$ (*3.000 é o ponto médio entre 2.000 e 4.000*)
 - $(\leq 7000) : (> 7000)$ (*7.000 é o ponto médio entre 4.000 e 10.000*)

Prós, Contras e Info. Complementares (6/7)

- Um mesmo atributo pode aparecer em diferentes nós da AD?
 - Sim, pode. Cada subárvore é construída de forma independente com os atributos/dados que compõem a sua partição.
- Veja o exemplo ao lado, em que:
 - “BAND_RATIO_BAND2”
 - “BAND_RATIO_BAND0”
 -
- aparecem em mais de 1 nó, em diferentes níveis da AD



Prós, Contrás e Info. Complementares (5/7)

- Qual o critério de parada?
 - No exemplo apresentado, o CART encerrou o seu processamento quando a última partição impura possuía um número pequeno de observações (apenas 3 observações).
 - Muitas ferramentas permitem com que o usuário configure este **número mínimo de observações** que leva ao fim do processamento.
 - Outro critério de parada usual é a **profundidade máxima** da árvore (número de níveis da raiz até o nó folha mais profundo)

Prós, Contras e Info. Complementares (6/7)

- **Conceitos importantes**

- Há vários outros conceitos mais avançados sobre ADs que não foram apresentados nessa aula, tais como:
 - Poda: técnica para reduzir o tamanho da AD com o objetivo de torná-la mais eficaz.
 - Outros algoritmos além do CART (ex.: C4.5)
 - Outras medidas de diversidade além do índice de Gini (ex.: entropia)
 - Algoritmo **Random Forest**, que utiliza um grupo de ADs no processo de classificação.

Prós, Contras e Info. Complementares (7/7)

- **CART na scikit-learn**

- Nossa próxima missão será “meter a mão na massa” .
- Vamos treinar um modelo de AD utilizando a ferramenta scikit-learn do Python.
- Você verá que essa ferramenta possui algumas especificidades! Não se preocupe, pois vamos discuti-las ao longo das próximas semanas.

TAREFA

Selecionar artigo para apresentar no seu seminário

Se não der tempo de definir hoje, ao menos selecione alguns candidatos e depois decida.

Quando você decidir, me envie o nome do artigo, ano e congresso (não precisa enviar o PDF) → eduardo.correa@ibge.gov.br.

IMPORTANTE: Você deverá escolher um artigo **publicado** a partir de **2023**.

Selecione um artigo dos sites dos seguintes congressos:

KDMile - <https://sol.sbc.org.br/index.php/kdmile/issue/archive>

ENIAC - <https://sol.sbc.org.br/index.php/eniac/issue/archive>

STIL - <https://sol.sbc.org.br/index.php/stil/issue/archive>

SBPO - <https://proceedings.science/sbpo>

EXERCÍCIO

- Considere a base de treinamento de uma locadora de veículos hipotética mostrada ao lado.
- Suponha que deseja-se aprender uma AD CART para classificar um cliente como “cliente de carro nacional” (Aluga=“N”) ou “cliente de carro importado” (Aluga=“I”) em função de sua “Idade” e “Renda”.
 - Responda: ao final do passo 1 do treinamento, qual atributo preditivo seria escolhido para o nó raiz da AD, “Idade” ou “Renda” ? Justifique (*mostre as contas...*).

Idade	Renda	Aluga (classe)
>40	≤8k	N
>40	≤8k	N
≤40	>8k	N
≤40	>8k	N
≤40	≤8k	N
≤40	≤8k	N
≤40	>8k	N
>40	≤8k	N
>40	≤8k	I
≤40	>8k	I
>40	>8k	I
≤40	>8k	I

Principais conceitos apresentados

- **Classificador** ou **Modelo de Classificação**: modelo utilizado para determinar a classe de objetos de maneira automática.
- **Base de Dados de Treinamento**: base de dados contendo objetos classificados, de acordo com classes pré-definidas, utilizada para o aprendizado de modelos de classificação..
- **Algoritmo de Classificação**: algoritmo que aprende (produz) um modelo de classificação a partir de uma base de dados de treinamento.
- **Atributos Preditivos** ou **Features**: atributos (variáveis) que contêm as características (*features*) dos objetos na base de treinamento.
- **Atributo Classe**: atributo armazena a classe dos objetos na base de treinamento..
- **Classificador Caixa Preta**: classificador que não explica as razões de suas classificações.
- **Classificador Caixa Branca** ou **Interpretável**: classificador capaz de explicar as razões de suas classificações .
- **Árvore de Decisão (AD)**: tipo de classificador interpretável que produz modelo no formato de árvore, uma estrutura gráfica e intuitiva que representa um conjunto de regras de classificação.
- **Medida de Diversidade**: medida que computa a pureza dos nós de uma AD.
- **CART**: um dos mais famosos algoritmos para o aprendizado de ADs.

Referências

HAN, J.; KAMBER, M. PEI, J. Classification: Basic Concepts. *In*: HAN, J.; KAMBER, M. PEI, J. **Data Mining: Concepts and Techniques**. 4. ed. Waltham: Morgan Kauffman, 2022. cap 8, p. 327 – 350.

ZAKI, M. J.; MEIRA JR., W. Decision Tree Classifier. *In*: ZAKI, M. J.; MEIRA JR. **Data Mining and Machine Learning Fundamental Concepts and Algorithms**. 2. ed. [s.l.]: Cambridge University Press, 2020. cap 19, p. 483 – 500. Disponível em: < https://dataminingbook.info/book_html/chap19/book.html >. Acesso em: 03 abr. 2025.