

Avaliação de Classificadores – Parte 1

Aula 05: Inteligência Computacional

Prof. Eduardo Corrêa Gonçalves

02/09/2026

Sumário

Sumário

Introdução


Métodos de Avaliação – Obtendo Estimativas Confiáveis

Medidas de Desempenho (Caso da Classificação Binária)

Introdução (1/6)

- **Classificação**


- Processo em que um modelo treinado é utilizado para **inferir a classe** de um **objeto** dentre um conjunto pré-definido de classes
- **Ex.:** Classificador de Sentimentos
 - Recebe um texto contendo uma opinião como entrada e, como saída, a classifica como “**Positiva**” ou “**Negativa**”



Introdução (3/6)

- O que é preciso para criar um classificador ?
 - Você precisa “somente” de **duas coisas**:
 - (1) Uma boa **base de dados de treinamento**.
 - **Base rotulada** – contendo **objetos classificados**, de acordo com **classes pré-definidas**.

Ao lado, uma base
p/ treinar um
classificador de
sentimentos



opinião sobre um filme (objeto)	sentimento (classe)
<i>Uma grande chatice!!!</i>	Negativa
<i>Totalmente previsível e sem ritmo :(</i>	Negativa
<i>Será que alguém gostou disso?</i>	Negativa
<i>Muito emocionante e potente</i>	Positiva
<i>O filme mais divertido que vi em 2026 !</i>	Positiva

- (2) E um bom **algoritmo de classificação**.
 - CART, Regressão Logística, Rede Neural Feed Forward, SVM, Random Forest etc.

Introdução (4/6)

- Mas o que é preciso para colocar o classificador em produção?
 - É preciso obter uma **estimativa confiável** de **sua acurácia**.
 - Isso é: empregar técnicas estatísticas para estimar se ele terá um **bom desempenho** para classificar **novos objetos**.
 - Você não vai arriscar a sua carreira colocando um classificador em produção sem ter a confiança de que ele é bom, *não é mesmo?*!
 - **Como é feito?**
 - 1º - escolhe-se um método de avaliação (ex.: **validação cruzada**).
 - 2º - empregando o método escolhido, obtém-se os valores estimados para um conjunto medidas de desempenho (ex.: **precision, recall**).

Introdução (5/6)

- Essa aula aborda o essencial sobre avaliação de modelos de classificação
 - Isto é, aquilo que necessariamente você precisa saber
 - É um assunto que costuma confundir os iniciantes. Por isso, algumas “**pegadinhas**” serão destacadas.
 - Toda pegadinha será marcada com o ícone:



Introdução (6/6)

- Pegadinha – A palavra “Acurácia”



- Na área de aprendizado de máquina, a **palavra acurácia tem 2 significados**:
- SIGNIFICADO 1: termo geral para indicar as habilidades preditivas do classificador.
 - Nesse caso, “acurácia” é **sinônimo** de “**eficácia**” e “**desempenho preditivo**”.
 - Ex1.: “*esse classificador de sentimentos é extremamente acurado*”
- SIGNIFICADO 2: termo que designa uma medida de desempenho específica.
 - Nesse caso, significa o percentual de acertos no conjunto de dados de teste.
 - Ex2.: “*esse classificador de sentimentos tem acurácia de 97%*”

Obtendo Estimativas Confiáveis (1/13)

- **O Princípio Básico** – princípio que deve ser adotado afim de que sejam obtidas estimativas de acurácia confiáveis.
 - Deve-se usar um **conjunto** de dados **de teste** contendo objetos classificados, porém **NÃO ENVOLVIDOS** no treinamento do classificador.

Obtendo Estimativas Confiáveis (2/13)

- **O Princípio Básico** – Deve-se usar um **conjunto** de dados **de teste** contendo objetos classificados, porém **NÃO ENVOLVIDOS** no treinamento do classificador.
- **Por que?**
 - Estimar a acurácia, significa estimar o **desempenho preditivo futuro** do classificador.
 - Ou seja:
 - Estimar a sua eficácia na produção, o quão bom ele será para classificar novos objetos.
 - Por isso, a qualidade do modelo precisa ser avaliada com objetos que ele não conheceu durante seu treinamento
 - Esses objetos têm o papel de simular os objetos futuros.

Obtendo Estimativas Confiáveis (3/13)

- Pegadinha – Avaliação **Resubstitution**




- Estimar a acurácia do classificador com os próprios dados que foram usados para treiná-lo é conhecido como *resubstitution*.
- Isso **não deve ser feito** !!!! **ERRADO**, **ERRADO**, **ERRADO**
 - A acurácia nos dados de treino **não é** um bom indicador de desempenho futuro.
 - O classificador terá sido treinado e avaliado com os mesmos dados.
 - Então, a estimativa de desempenho tenderá a ser **otimista**
 - Às vezes, **extremamente otimista**, se o modelo estiver **superajustado** (*overfitted*) aos dados de treino.
- É preciso adotar outra técnica. As duas mais usadas são: *holdout* e validação cruzada.

Obtendo Estimativas Confiáveis (4/13)

- **Avaliação Holdout**

- Método mais simples para estimar a acurácia de um classificador.
 - Divide aleatoriamente a base de treinamento em 2 partições:
 - **Treino** (ex.: 2/3 da base)*
 - **Teste** (ex.: 1/3 da base)



- **Treina** o modelo usando a partição de treino.
- **Testa** (ou avalia) o modelo treinado usando a partição de teste.
 - Como veremos, testar significa obter valores de medidas de desempenho que indicam a **efetividade** (qualidade da classificação) na partição de teste sob diferentes aspectos.

* Não precisa ser necessariamente 2/3 x 1/3. Pode ser 80% x 20%, 90% x 10% etc.

Obtendo Estimativas Confiáveis (5/13)

- Estratificação



- Idealmente, a divisão TREINO e TESTE deve ser feita de forma **estratificada**.
 - Garantindo que cada classe seja propriamente representada em ambas as partições.
 - **Ex.:** no BD há 75% objetos da classe A e 25% da classe B.
 - Ao dividir em TREINO e TESTE essa proporção deverá ser mantida (o quanto for possível) em ambas as partições.

Obtendo Estimativas Confiáveis (6/13)


- Desvantagens da Avaliação Holdout



- PROBLEMA 1:** de acordo com a literatura, a estimativa de acurácia tende a ser **pessimista**, pois apenas uma porção inicial dos dados rotulados será usada para derivar o modelo.
- PROBLEMA 2:** “apostamos” tudo em uma única avaliação, onde modelo foi construído com uma única partição de treino, gerada de forma aleatória.
 - Parece arriscado...*

Obtendo Estimativas Confiáveis (7/13)

- **Validação Cruzada (*k-folds cross-validation*)**
 - Método mais utilizado para estimar a qualidade de um classificador.
 - Divide aleatoriamente (e, de preferência, estratificadamente) base de treinamento em k partições iguais (ex.: $k = 10$)



- **Treina** o modelo de classificação usando $k-1$ partições.
- **Testa** o modelo treinado sempre usando 1 partição
 - Repete esse procedimento k vezes, mudando a partição de teste a cada rodada (e, por consequência, as partições de treino).
 - Acurácia final = média da acurácia das k rodadas.

Obtendo Estimativas Confiáveis (8/13)

- Validação Cruzada (*k-folds cross-validation*)

- Por exemplo, na **primeira** rodada:
 - Treina modelo com partições: 1, 2, 3, 4, 5, 6, 7, 8, 9
 - Testa com a partição 10

1	2	3	4	5	6	7	8	9	10
---	---	---	---	---	---	---	---	---	----

- Então, na **segunda** rodada:
 - Treina o modelo com as partições: 1, 2, 3, 4, 5, 6, 7, 8, 10
 - Testa com a partição 9

1	2	3	4	5	6	7	8	9	10
---	---	---	---	---	---	---	---	---	----

- E assim sucessivamente, até que as 10 partições tenham sido usadas como teste.

Obtendo Estimativas Confiáveis (9/13)

- Validação Cruzada (*k-folds cross-validation*)

- A validação cruzada (CV), garante que, a cada rodada, o modelo seja testado com objetos que não foram usados em seu treinamento.

- É muito comum usar $k = 10$ (abreviado por **10-CV**). Por que?

1	2	3	4	5	6	7	8	9	10
---	---	---	---	---	---	---	---	---	----

- Principalmente por razões empíricas. Inúmeros testes evidenciaram que 10 é o número ideal para obter a melhor estimativa de acurácia.
- Entretanto:
 - Se a base rotulada é pequena, dividir em 10 produz partições contendo poucos objetos.
 - Por outro lado, se a base é muito volumosa, 10 rodadas de avaliação torna o processo de teste demorado.
 - Nesses casos, muitas pessoas preferem fazer **5-CV**.



1	2	3	4	5
---	---	---	---	---

Obtendo Estimativas Confiáveis (10/13)

- Algumas Pegadinhas 

- Pegadinha 1: Supondo que a estimativa de acurácia obtida pelo *holdout* ou validação cruzada tenha sido satisfatória... **como devo gerar o modelo final?**
 - Você deve gera-lo com o **BD rotulado completo !!!**
 - O modelo final é o que irá para a produção, então use todos os dados rotulados disponíveis, ora bolas !!!

BD ROTULADO COMPLETO (ORIGINAL)



Obtendo Estimativas Confiáveis (11/13)

- Pegadinhas (*continuação*) 
- Pegadinha 2: Um dado site (ex.: Kaggle) já fornece as partições de TREINO e TESTE em arquivos separados.
 - **Devo usá-las** no meu processo de holdout?
 - Em geral, a resposta é **sim** !
 - Isso lhe permitirá comparar os resultados de seu modelo com os resultados de outras pessoas.
 - Do ponto de vista metodológico, não é correto comparar resultados de modelos que não usaram as mesmas partições para treino e teste.
 - Você só não vai usá-las se a divisão estiver mal feita (por exemplo, se foi feita sem estratificação).

Obtendo Estimativas Confiáveis (12/13)

- Pegadinhas (*continuação*)



- Pegadinha 3: Eu mesmo dividi aleatoriamente o BD em partições (seja em TREINO-TESTE ou em k partições)
 - **Devo então guardar** as partições geradas e a semente utilizada?
 - **Sim**, você deve fazer isso.
 - No mínimo guarde a semente. Isso é fundamental para garantir a geração das mesmas partições, caso seja preciso no futuro.
 - A vantagem de também guardar as partições é que você não precisará gera-las novamente se quiser usá-las em outro experimento ou se for reexecutar seu experimento.

Obtendo Estimativas Confiáveis (13/13)

- **Outros métodos**
 - **Repeated cross-validation:** repete a k -CV por n vezes, gerando, de forma aleatória, diferentes partições estratificadas a cada vez.
 - Por exemplo, repete a 10-CV por 10 vezes. Com isso, realiza-se o treino e teste 100 modelos diferentes. Muitos livros recomendam.
 - De maneira análoga, existe o *repeated holdout*.
 - **Leave-one-out:** caso especial da validação cruzada, usado quando a base rotulada é muito pequena.
 - k é definido como N (onde N é o número de objetos do BD)
 - Assim, serão realizadas N rodadas de avaliação. Em cada uma, apenas 1 documento será usado como teste.
 - **Bootstrap:** realiza a amostragem dos objetos de treino de maneira uniforme, com reposição.
 - *Não será coberto em nosso curso.*

Medidas de Desempenho (1/15)

- **Classificadores Binários**

- Veremos agora como funciona a avaliação de **classificadores binários**
 - Tratam-se dos classificadores usados em problemas envolvendo **2 classes**, tais como:
 - Classificação de Spam
 - classes: “sim” (e-mail é spam) x “não” (e-mail é normal)
 - Classificação de Fraudes
 - classes: “sim” (transação é uma fraude) x “não” (transação é normal)
 - Predição de Compra de um Produto
 - classes: “sim” (cliente vai comprar) x “não” (não vai comprar)
 - Diagnose de Doença
 - classes: “sim” (paciente tem uma certa doença) x “não” (não tem)
 - Os **classificadores multiclasse** (para problemas com **mais de 2 classes**) serão cobertos em uma **aula futura**.

Medidas de Desempenho (2/15)

- As classes “Positiva” e “Negativa”
 - Em problemas binários, costumamos chamar de **classe positiva** (**classe 1** ou **“Sim”**) aquela de **maior interesse** no problema.
 - Por consequência, a outra classe se torna a **classe negativa** (**classe 0** ou **“Não”**).
 - **Predição de compra de um produto:**
 - Compra = “Sim” → é a classe positiva.
 - Compra = “Não” → é a classe negativa.
 - **Detecção de fraude:**
 - Fraude = “Sim” → é a classe positiva.
 - Fraude = “Não” → é a classe negativa.
 - **Detecção de discurso de ódio:**
 - Texto ofensivo = “Sim” → é a classe positiva.
 - Texto ofensivo = “Não” → é a classe negativa.
 - *Sem dúvida, “fraude” e “ódio” são coisas negativas... porém, como são as classes de maior interesse nos problemas acima, são tratadas como classe 1.*

Medidas de Desempenho (3/15)

- As classes “Positiva” e “Negativa”
 - E o no caso da **Análise de Sentimentos** ?
 - Nesse caso, (felizmente) a convenção é:
 - A classe “opinião positiva” ser a classe positiva (classe 1).
 - A classe “opinião negativa” ser a classe negativa (classe 0).
 - Isso costuma ocorrer, mesmo quando o maior interesse do usuário são os documentos classificados como opinião negativa.

Medidas de Desempenho (4/15)

- **Avaliação de Classificadores Binários**
 - Agora apresentaremos as medidas (ou métricas) de desempenho aplicadas aos classificadores binários.
 - Elas indicam, sob diferentes aspectos, o quão bom ou quão acurado é o classificador que você treinou.
 - As métricas que apresentaremos podem ser calculadas a partir de uma importante estrutura conhecida como **matriz de confusão** (MC).

		Rótulos Preditos	
	Classes	Não	Sim
Rótulos Reais	Não	VN	FP
	Sim	FN	VP

Medidas de Desempenho (5/15)

- **Matriz de Confusão (MC)**

- A MC é simplesmente uma matriz quadrada que indica as classificações corretas e erradas após o classificador ter sido testado.
- Nesta aula, as MCs serão sempre estruturadas considerando as classes “Não” (negativa) e “Sim” (positiva).

		Rótulos Preditos	
	Classes	Não	Sim
Rótulos Reais	Não	VN	FP
	Sim	FN	VP

Medidas de Desempenho (6/15)

- **Matriz de Confusão (MC)**

- É sempre possível gerar uma MC após a finalização do processo de teste de uma partição.
- **Na avaliação *holdout*:** uma única matriz pode ser gerada, resumindo os resultados no BD de teste
- **Na validação cruzada:** pode-se gerar k matrizes (cada uma referente ao teste de uma partição) e, adicionalmente, uma MC geral (soma de todas as outras matrizes).

		Rótulos Preditos	
	Classes	Não	Sim
Rótulos Reais	Não	VN	FP
	Sim	FN	VP

Medidas de Desempenho (7/15)

- **Matriz de Confusão – valores nas células**
 - **VN**: verdadeiro negativos → objetos de teste da classe negativa que foram corretamente classificados como negativos.
 - **FP**: falso positivos → objetos de teste da classe negativa, incorretamente classificados como positivos.
 - **FN**: falso negativos → objetos de teste da classe positiva, incorretamente classificados como negativos.
 - **VP**: verdadeiro positivos → objetos de teste da classe positiva que foram corretamente classificados como positivos
- Veja que a **diagonal** da MC abrange as **classificações corretas**.

		Rótulos Preditos	
	Classes	Não	Sim
Rótulos Reais	Não	VN	FP
	Sim	FN	VP

Medidas de Desempenho (8/15)

- **Medida da Acurácia**

- A partir da matriz de confusão, diversas medidas de desempenho podem ser calculadas.
- A mais conhecida é a **Acurácia** → Percentual de classificações corretas na base de teste.

- $\text{Acurácia} = (VP + VN) \div (VN + FP + FN + VP)$

- **Exemplo:**

- $\text{Acurácia} = (6954 + 2588) \div (6954 + 412 + 46 + 2588) = \underline{95,42\%}$

		Rótulos Preditos	
	Classes	Não	Sim
Rótulos Reais	Não	2588 (VN)	412 (FP)
	Sim	46 (FN)	6954 (VP)

Medidas de Desempenho (9/15)

- Medida da Acurácia

- Exemplo:** cálculo da acurácia a partir da matriz de confusão gerada após o teste de um **classificador de fraudes**.

		Rótulos Preditos	
	Classes	Fraude="Não"	Fraude="Sim"
Rótulos Reais	Fraude="Não"	900 (VN)	90 (FP)
	Fraude="Sim"	4 (FN)	6 (VP)

- $$\text{Acurácia} = (VP + VN) \div (VN + FP + FN + VP)$$

$$= 906 \div 1000 = \underline{90,60\%}$$
- Essa acurácia é satisfatória?
- Você colocaria esse classificador em produção?

Medidas de Desempenho (10/15)

- **Problemas da Medida de Acurácia**

- É um resultado que reflete a média de desempenho do classificador considerando as duas classes.
- Com isto, pode mascarar situações onde o classificador apresenta performance preditiva ruim para algum rótulo específico.
- Apesar da Acurácia de 90,60% (aparentemente alta) a matriz de confusão mostra claramente que o desempenho do classificador é bem melhor para a classe negativa (Fraude="Não") do que para a classe positiva (Fraude="Sim") .

		Rótulos Preditos	
		Fraude="Não"	Fraude="Sim"
Rótulos Reais	Fraude="Não"	900 (VN)	90 (FP)
	Fraude="Sim"	4 (FN)	6 (VP)

Medidas de Desempenho (11/15)

- **Especificidade e Sensibilidade**
 - **SOLUÇÃO:** utilizar a Acurácia em conjunto com outras medidas.
 - Exemplos:
 - **Especificidade:** avalia o desempenho da classe negativa.
 - $\text{Especificidade} = \text{VN} \div (\text{VN} + \text{FP}) = 900 \div (900 + 90) = 90,90\%$
 - **Sensibilidade:** avalia o desempenho da classe positiva.
 - $\text{Sensibilidade} = \text{VP} \div (\text{VP} + \text{FN}) = 6 \div (6 + 4) = 60,00\%$

		Rótulos Preditos	
		Fraude="Não"	Fraude="Sim"
Rótulos Reais	Fraude="Não"	900 (VN)	90 (FP)
	Fraude="Sim"	4 (FN)	6 (VP)

Medidas de Desempenho (12/15)

- **Precisão (*precision*) e Revocação (*recall*)**
 - São duas medidas muito populares, especialmente em problemas de classificação de texto.
 - **Precisão**: é uma medida de exatidão → percentual de objetos rotulados como positivos que, de fato, são positivos.
 - $\text{Precisão} = VP \div (VP + FP) = 6 \div (6 + 90) = 6,25\%$
 - **Revocação**: é uma medida de completude → qual o percentual de objetos positivos que foram rotulados como positivos. Mesmo que sensibilidade.
 - $\text{Revocação} = VP \div (VP + FN) = 6 \div (6 + 4) = 60,00\%$

		Rótulos Preditos	
		Fraude="Não"	Fraude="Sim"
Rótulos Reais	Fraude="Não"	900 (VN)	90 (FP)
	Fraude="Sim"	4 (FN)	6 (VP)

Medidas de Desempenho (13/15)

- Medida F1
 - Média harmônica da precisão e revocação.
 - $F1 = (2 \times \text{Precisão} \times \text{Revocação}) \div (\text{Precisão} + \text{Revocação})$
 - Considerando o exemplo anterior:
 - $F1 = (2 \times 0,0625 \times 0,6) \div (0,0625 + 0,6) = 11,32\%$
- **Obs.:** A F1 é *um tipo* de F-Measure (ver artigo da Wikipedia que explica bem...)

Medidas de Desempenho (14/15)

- Por que a F1 é usada?
 - MOTIVO 1: Ela fornece um valor mais “equilibrado” da efetividade do sistema, tendo em vista que a Precision ignora FNs e o Recall ignora FPs.
 - MOTIVO 2: Porque, na prática, quando atuamos para melhorar a Precision de um sistema, o Recall acaba piorando (e vice-versa).
 - Muitas vezes, o ideal é tentar chegar em uma situação de equilíbrio.
 - ... Mas **nem sempre**... Por exemplo, na **classificação de discurso de ódio**, em algumas situações a atenção poderá ser maior na classe “sim”, então a prioridade é maximizar a precisão do sistema.
 - Nesse caso, o usuário considera melhor um erro que classifica comentário normal como ódio, do que classificar ódio como texto normal.

Medidas de Desempenho (15/15)

- Pegadinha – **Posição das Classes na MC**



- Cuidado, pois os livros e ferramentas não seguem uma padronização para a posição das classes positiva e negativa na MC.
 - Alguns colocam primeiro a negativa (forma aqui adotada) e outros a positiva.

		Rótulos Preditos	
	Classes	Fraude="Não"	Fraude="Sim"
Rótulos Reais	Fraude="Não"	900 (VN)	90 (FP)
	Fraude="Sim"	4 (FN)	6 (VP)

		Rótulos Preditos	
	Classes	Fraude="Sim"	Fraude="Não"
Rótulos Reais	Fraude="Sim"	6 (VP)	4 (FN)
	Fraude="Não"	90 (FP)	900 (VN)

Referências

HAN, J.; KAMBER, M. PEI, J. Classification: Basic Concepts. *In*: HAN, J.; KAMBER, M. PEI, J. **Data Mining: Concepts and Techniques**. 3. ed. Waltham: Morgan Kauffman, 2024. cap 8, p. 364 – 371.