

Clustering – conceitos básicos: k-Médias, Inertia (SSE), Silhueta

Aula 08 – Inteligência Computacional

Eduardo Corrêa Gonçalves

16/09/2026

Sumário

Introdução

O que é *clustering* (ou análise de agrupamentos) ?

Exemplos de aplicações

Conceitos básicos sobre clustering

Desafios

Algoritmo k-Médias – exemplo passo a passo

Deficiência do k-Médias: as que podem ser contornadas e as que não podem

Inertia


Escolhendo k – método do cotovelo

Avaliando os clusters gerados – método da silhueta

Introdução (1/6)

Análise de Agrupamentos (*Clustering*)

- Processo em que um **algoritmo** é empregado para **dividir automaticamente** um conjunto de objetos (base de dados) em **grupos** de acordo com algum relacionamento de **similaridade** entre os objetos.
- Cada grupo definido é chamado de **cluster**.



Fonte: Soares (2004)


Introdução (2/6)

Análise de Agrupamentos (*Clustering*)

O algoritmo deve ser capaz de organizar os objetos em cada cluster de forma que haja:

Alta similaridade entre os objetos pertencentes a um **mesmo cluster**
(similaridade intra-cluster)

Baixa similaridade entre objetos que pertencem a **clusters diferentes**
(similaridade inter-cluster).



Introdução (3/6)

Por que determinar agrupamentos?

- **MOTIVO 1: Viabilizar a segmentação.**
 - BDs podem conter objetos (pessoas, imagens, textos, produtos etc.) descritos por dezenas, centenas ou milhares de atributos.
 - Segmentar esses objetos de forma manual, usando planilhas, é inviável. Desta forma, precisamos da ajuda de um algoritmo.
- **MOTIVO 2: Buscar pelo novo.**
 - A determinação de agrupamentos ajuda a identificar segmentos novos (desconhecidos pelos especialistas), interessantes e lucrativos.
- **MOTIVO 3: Sair do zero.**
 - Há situações em que as relações entre os objetos de uma BD são inteiramente desconhecidas (ex.: a base é nova).
 - Nesse caso, o *clustering* pode servir como uma boa técnica exploratória.

Introdução (4/6)


Exemplos de Aplicações

Administração Pública / Ciências Sociais

- A partir dos dados do Censo de 1991, um processo de análise de agrupamentos identificou 5 tipos de microáreas urbanas no RJ (CARVALHO et al. 1997):
 - (A) alta renda;
 - (B) renda mais baixa;
 - (C) pobre, com predomínio de casas alugadas;
 - (D) baixa escolaridade e renda;
 - (E) precariedade no saneamento básico.

Introdução (5/6)

- **Exemplos de Aplicações - Detecção de Anomalias** ([esse é um MOTIVO 4 p/ fazer clustering!](#))
 - Objetos que não estão muito próximos de nenhum *cluster* são dissimilares aos demais objetos e podem representar anomalias.
 - Pode ser um simples **erro** nos dados
 - Mas pode ser uma **fraude**:
 - transação financeira fraudulenta;
 - usuário mal intencionado em uma rede social;
 - formulário preenchido com dados falsos;
 - ...




Fonte: Han et al. (2023)

Introdução (6/6)

Exemplos de Aplicações

Segmentação de imagens

- Processo de particionar uma imagem digital em múltiplas regiões distintas, contendo conjunto de pixels com atributos similares.



Fonte: <https://www.kdnuggets.com/2019/08/introduction-image-segmentation-k-means-clustering.html>

- Há muitas aplicações de análise de agrupamentos que utilizam **imagens de satélite** ou **drones** para sensoriamento remoto, mapeamento de solos etc.

Como fazer Análise de Agrupamentos ? (1/6)

Você precisa de “apenas” duas coisas:

1. Um bom **algoritmo de clustering** para o seu problema.

Exemplos: k-Médias, DBScan, Self-Organizing Maps, Hierárquico Aglomerativo, ...

2. Uma boa **base de dados**.

Esta base deve conter **objetos** descritos por um conjunto de características (*features*) X .

importante: **não existe** variável y !!!

clustering é uma tarefa de **aprendizado não supervisionado**,

Como fazer Análise de Agrupamentos ? (2/6)

Aprendizado Supervisionado

Em problemas desse tipo, o algoritmo constrói um modelo a partir de uma base de dados de treinamento em que os objetos são pares (*features* **X**; *variável alvo* **y**).

O objetivo do algoritmo será criar uma função de mapeamento $y = f(X)$

Exemplos de tarefas: *classificação* e a *regressão*.

Aprendizado Não Supervisionado

Em um problema não supervisionado o algoritmo explora uma base de dados contendo apenas as *features* **X** dos objetos (**não existe** a variável **y**)


Assim, o algoritmo deve descobrir por si só os possíveis relacionamentos entre os objetos.

Exemplos de tarefas: *clustering* e a *descoberta de padrões frequentes*.

Como fazer Análise de Agrupamentos ? (3/6)

Desafio – *clustering* é subjetivo !

Se você tivesse que dividir estes objetos em **dois clusters**, como você faria?




* Exemplo retirado do tutorial "**A Gentle Introduction to Machine Learning and Data Mining for the Database Community**" apresentado por Eamonn Keogh no 18º Simpósio Brasileiro de Bancos de Dados – SBBD 2003

Como fazer Análise de Agrupamentos ? (4/6)

Clustering é subjetivo !


Exemplo 1



Família

Escola

Exemplo 2



Mulheres

Homens

- **Outros exemplos:** crianças x adultos; fumantes x não-fumantes; inteligentes x nem tanto, ...
- Diferentes variáveis para definir o(s) aspecto(s) de similaridade levarão a diferentes resultados. *Além do algoritmo e base de dados, temos que pensar nisso...*

Como fazer Análise de Agrupamentos ? (5/6)

Similaridade – Há 2 principais desafios

- Similaridade pode ser algo **subjetivo** e **difícil de quantificar**...
 - ... e o computador não gosta disso.
- Há **diferentes aspectos** na similaridade...
 - ... dois objetos podem ser similares em certos aspectos e dissimilares em outros.



- 50% das pessoas acham o bebê a cara da mãe.
 - Talvez por causa do nariz.
- 50% acham a cara do pai.
 - Talvez por causa do sorriso.

Como fazer Análise de Agrupamentos ? (6/6)

Muitos nomes para a mesma tarefa...

Clustering é um tópico estudado estatística, mineração de dados, AM, IC e muitas outras áreas.

Por isso, ela é conhecida por diversos outros nomes:

Análise de agrupamentos

Determinação de agrupamentos

Segmentação de dados

Classificação não supervisionada

Taxonomia automática

Clusterização

...

Algoritmo k-Médias – exemplo passo a passo (1/6)


- **Algoritmo k-Médias (*k-Means*)**

- Proposto em 1967, é o mais tradicional para a determinação de agrupamentos.
- Como **entrada** o algoritmo deve receber:
 - Uma **base de dados (BD)** com d dimensões.
 - O número de clusters que desejamos determinar (**parâmetro k**).
- Demonstraremos o **funcionamento básico** do algoritmo para a BD bidimensional ao lado, usando **$k = 3$** .

x1	x2
3	9
3	5
8	2
1	1
9	4
9	5
1	8
2	3
4	3
7	3
2	6
9	9
4	7

Algoritmo k-Médias – exemplo passo a passo (2/6)


- **PASSO 1:** Escolher k objetos da BD para representar os **centros iniciais** (**sementes**) dos *clusters*.



- Nesse exemplo, os 3 primeiros objetos da BD (3,9), (3,5) e (8,2) foram escolhidos para representar os centros iniciais.
- Porém, o ideal é escolher de forma aleatória ou escolher pontos que não estejam próximos.

Algoritmo k-Médias – exemplo passo a passo (3/6)


- **PASSO 2:** cada objeto é associado a um *cluster* utilizando uma medida de distância.



- É preciso medir a **distância** entre **cada objeto** e **todos os centros de clusters** (usando a Distância Euclidiana, por exemplo).
- Cada objeto deve ser associado ao *cluster* cujo centro esteja **mais próximo** dele.
- **Exemplo:** Objeto (9,4) deve ser associado ao *cluster* de centro (8,2)

Algoritmo k-Médias – exemplo passo a passo (4/6)

- **Resultado ao final do passo 2** → a composição corrente dos clusters C1, C2 e C3 foi definida.




C1 = (1,1), (2,3), (2,6), (3,5) e (4,3)

C2 = (1,8), (3,9), (4,7) e (9,9)

C3 = (7,3), (8,2), (9,4) e (9,5)

Algoritmo k-Médias – exemplo passo a passo (5/6)

- PASSO 3: calcular os novos centros dos *clusters***



Clusters atuais:

C1 = (1,1), (2,3), (2,6), (3,5) e (4,3)


C2 = (1,8), (3,9), (4,7) e (9,9)

C3 = (7,3), (8,2), (9,4) e (9,5)

- São obtidos por média aritmética:
 - $z1^* = 1/5 \times (1+2+2+3+4, 1+3+6+5+3) = (12/5, 18/5) = (2.40, 3.60)$
 - Analogamente: $z2^* = (4.25, 8.25)$ e $z3^* = (8.25, 3.50)$

Algoritmo k-Médias – exemplo passo a passo (6/6)

- **PASSO 4:** verificar se os centros dos novos clusters são diferentes dos anteriores (eles se “movimentaram” ?)



Centros anteriores:

$$z_1 = (3,9)$$

$$z_2 = (3,5)$$

$$z_3 = (8,2)$$

Novos centros:

$$z_1 = (2.40, 3.60)$$

$$z_2 = (4.25, 8.25)$$

$$z_3 = (8.25, 3.50)$$

- Se os centros dos clusters **se movimentaram** (foi o que ocorreu) o algoritmo **retorna ao 2º passo** (associar cada objeto a um cluster de acordo com a medida da distância). Caso contrário, o algoritmo **convergiu** e pode ser **encerrado**.
 - **alternativas:** executar p/ um número máximo definido de iterações ou até o deslocamento dos centros ser inferior a um limiar (usuário pode definir)

Reproduzindo o exemplo na scikit-learn (1/5)

Vamos agora reproduzir o exemplo na sklearn

Passo 1: definição da base de dados alvo do processo

Como é um exemplo, definimos diretamente no código.

Na prática, você vai importar de um arquivo CSV ou banco de dados.

***** IMPORTANTE:** como sabemos, em um problema real, **quase sempre precisamos pré-processar** a base de dados

Ex.: colocar atributos na mesma escala, converter atributos categóricos para numéricos, tratar valores ausentes etc.

Mas nesse exemplo, a base é bem simples e não será necessário

	x1	x2
0	3	9
1	3	5
2	8	2
3	1	1
4	9	4
5	9	5
6	1	8
7	2	3
8	4	3
9	7	3
10	2	6
11	9	9
12	4	7

```
import pandas as pd
dados = {"x1": [3, 3, 8, 1, 9, 9, 1, 2, 4, 7, 2, 9, 4],
         "x2": [9, 5, 2, 1, 4, 5, 8, 3, 3, 3, 6, 9, 7]}

bd = pd.DataFrame(dados)
```

Reproduzindo o exemplo na scikit-learn (2/5)

Passo 2: geração dos clusters

- (1). **importar o pacote** com o algoritmo que você quer usar, nesse caso kMeans (módulo sklearn.cluster da scikit)
- (2). **Instanciar o objeto**, indicando os parâmetros que você deseja.
Instanciar é como carregar o algoritmo em memória para posterior utilização.
- (3). Usar o método (função) **fit**, para **gerar os clusters**, indicando a BD.

```
# (1). importa as classes KMeans do módulo sklearn.cluster
from sklearn.cluster import KMeans
# (2). cria um objeto k-Means e define os parâmetros
#     n_clusters = 3      : número de clusters, especificado como 3
#                           (nosso "k")
#     random_state = 0    : para garantir reprodutibilidade
#     init          : pontos que servirão como centros iniciais dos clusters
modelo = KMeans(n_clusters=3, init=[(3,9), (3,5), (8,2)],
random_state=0)

# (3). gera os clusters com o método fit(), indicando a BD
#     (e, se for o caso, os atributos que serão utilizados)
modelo.fit(bd)
```

Reproduzindo o exemplo na scikit-learn (3/5)


Resultado ao final do passo 2

Cada objeto da base de dados foi associado a um cluster.

Podemos visualizar:

- os centros dos clusters com a propriedade `cluster_centers_`
- o cluster associado a cada objeto com a propriedade `labels_`. Nesse caso, cluster 0, 1 ou 2 (já que definimos `k=3`)

```
print('Clusters gerados com sucesso!\n');
print("- Centro dos clusters:"); print(modelo.cluster_centers_); print()
print("- clusters de cada objeto:"); print(modelo.labels_)
```



```
Clusters gerados com sucesso!

- Centro dos clusters:
[[4.25 8.25]
 [2.4  3.6 ]
 [8.25 3.5 ]]

- clusters de cada objeto:
[0 1 2 1 2 2 0 1 1 2 1 0 0]
```

x1	x2
3	9
3	5
8	2
1	1
9	4
9	5
1	8
2	3
4	3
7	3
2	6
9	9
4	7

Reproduzindo o exemplo na scikit-learn (4/5)

Passo 3: Visualizar os clusters

Há várias formas de visualizar... No exemplo abaixo:


Criamos um clone da BD...

Depois inserimos uma coluna com os clusters e ordenamos a BD por essa coluna.

```
# cria um clone da base de dados
bd2 =
bd.copy()

# insere uma coluna com os clusters
bd2['cluster'] = modelo.labels_

# ordena as linhas pelo num. do
cluster
bd2.sort_values(by=["cluster"])
```



	x1	x2	cluster
0	3	9	0
6	1	8	0
12	4	7	0
11	9	9	0
7	2	3	1
10	2	6	1
3	1	1	1
1	3	5	1
8	4	3	1
4	9	4	2
2	8	2	2
5	9	5	2
9	7	3	2



Reproduzindo o exemplo na scikit-learn (5/5)

Passo 3: Visualizar os clusters

Podemos também produzir um gráfico colorindo os objetos de acordo com o seu cluster


```
import numpy as np
clusters = bd2['cluster'].to_numpy()
colormap = np.array(['red', 'lime', 'blue'])
figura = bd2.plot(kind="scatter", x="x1", y="x2", grid=True,
xlim=(0,10), ylim=(0,10), s=50, c=colormap[clusters],
figsize=(6,3))
```

- **IMPORTANTE:** quando a base de dados possui mais de 3 dimensões (atributos), podemos utilizar métodos como **PCA** e **t-SNE** para fazer uma **projeção em 2D**.



Algoritmos de Particionamento (1/1)

- K-médias é da família dos algoritmos baseados em **Particionamento**
 - **Características:**
 - Dividem os objetos em **k clusters** de formato esférico.
 - Baseados em **distância**: um objeto irá pertencer ao cluster cujo centro estiver mais próximo.
 - **Heurísticos**: utilizam um mecanismo iterativo de realocação, que tenta melhorar o particionamento movimentando objetos de um cluster para o outro, até chegar a um bom particionamento.
 - **Algoritmos:**
 - **k-Means**
 - **k-Medoids (PAM e CLARA)**
 - **k-Modes**
 - **k-Prototypes**
 - **Mini Batch k-Means**



Algoritmos de Particionamento (2/2)

- **Outros Algoritmos de Particionamento:**
 - **k-Medoids:** Em vez de calcular o valor médio dos objetos, escolhe **objetos reais** como **centróides** para diminuir a sensibilidade a outliers.
 - **k-Modes:** variante do k-Means para **variáveis nominais**. Usa a moda para determinar o centróide dos clusters.
 - **k-Prototypes:** combina o **k-Means** e o **k-Modes**, para tratar variáveis numéricas e nominais ao mesmo tempo.
 - **Mini-Batch k-Means:** variação do k-Means voltada para redução do tempo computacional
 - Há ainda os **métodos híbridos**, como o **Bisecting k-Means** (é, ao mesmo tempo, das famílias particionamento e hierárquico).
 - Detalhes nas referências.

Contornando algumas deficiências do k-Médias (1/8)

- **Principais Vantagens do k-Médias**

- Simples de entender e utilizar.
- Boa técnica *baseline*

- **Principais Desvantagens**

- Para uma mesma BD e um mesmo valor de k , pode apresentar resultados diferentes para diferentes sementes (centros iniciais).
 - Isso é: pode convergir para um local mínimo.
- Obriga usuário a escolher k – há problemas não há motivo p/ fazer isso de antemão.
- Gera clusters esféricos e tem dificuldade p/ lidar com fronteiras não lineares.
 - Vamos ver como contornar as 2 primeiras desvantagens

Contornando algumas deficiências do k-Médias (2/8)

Tratando o problema 1: fugindo do ótimo local

- Seja um conjunto com n pontos (objetos) $p_1, p_2, \dots, p_n$ em um espaço d -dimensional.
- O algoritmo k -Médias tem por objetivo determinar k clusters $C_1, C_2, \dots, C_k$ de centróides $c_1, c_2, \dots, c_k$, onde os objetos dentro de cada cluster devem ser semelhantes.
- Para tal, ele trabalha tentando separar os objetos em k grupos de variância igual, minimizando a função objetivo chamada **inertia** ou **soma do erro quadrado intra-cluster (SSE)**.

$$Inertia = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

Contornando algumas deficiências do k-Médias (3/8)

Mitigando o problema do ótimo local

A função visa mensurar o **quão internamente coerentes** são os clusters. Quanto menor o valor, melhor

- p é um objeto do cluster C_i , cujo centro é c_i .
- Para cada objeto em cada cluster, $dist(p, c_i)$, a distância do objeto ao centróide é elevada ao quadrado e todas as distâncias são somadas.

No exemplo ao lado → $Inertia = ((3-4.25)^2 + (9-8.25)^2) + ((1-4.25)^2 + (8-8.25)^2) + ((4-4.25)^2 + (7-8.25)^2) + ((9-4.25)^2 + (9-8.25)^2) + ((2-2.4)^2 + (3-3.6)^2) + ((2-2.4)^2 + (6-3.6)^2) + ((1-2.4)^2 + (1-3.6)^2) + ((3-2.4)^2 + (5-3.6)^2) + ((4-2.4)^2 + (3-3.6)^2) + ((9-8.25)^2 + (4-3.5)^2) + ((8-8.25)^2 + (2-3.5)^2) + ((9-8.25)^2 + (5-3.5)^2) + ((7-8.25)^2 + (3-3.5)^2) = \underline{65.65}$

$$Inertia = \sum_{i=1}^k \sum_{p \in C_i} dist(p, c_i)^2$$

- Centro dos clusters:
 $\begin{bmatrix} 4.25 & 8.25 \\ 2.4 & 3.6 \\ 8.25 & 3.5 \end{bmatrix}$

	x1	x2	cluster
0	3	9	0
6	1	8	0
12	4	7	0
11	9	9	0
7	2	3	1
10	2	6	1
3	1	1	1
1	3	5	1
8	4	3	1
4	9	4	2
2	8	2	2
5	9	5	2
9	7	3	2

Contornando algumas deficiências do k-Médias (4/8)


Mitigando o problema do ótimo local

- O algoritmo k -Médias sempre converge, porém muitas vezes para um ótimo local.
 - Entretanto, é sabido que isso depende bastante da escolha das sementes (centro de clusters iniciais).
- Para mitigar esse problema, a sklearn faz o seguinte:
 - Executa o algoritmo várias vezes, usando sementes diferentes.
 - As sementes escolhidas devem ser objetos que estejam (relativamente) distantes.
 - Como resultado final, escolhe-se os resultados da execução com menor ***inertia***.

Contornando algumas deficiências do k-Médias (5/8)

Tratando o problema 2: Encontrar um bom valor de k


- Em certas situações, você possui algum conhecimento a priori sobre o verdadeiro número de agrupamentos.
 - Às vezes, o número de *clusters* é determinado pelas restrições do problema ou pelo conhecimento do pesquisador.
- Porém, no “mundo real”, muitas vezes não temos nenhum conhecimento a priori.
- Neste caso, é comum utilizar a técnica conhecida como **método do cotovelo** (*elbow method*).



Contornando algumas deficiências do k-Médias (6/8)

Encontrando um bom valor de k – método do cotovelo


- O método do cotovelo avalia como a homogeneidade dentro dos agrupamentos se altera para diferentes valores de k .
- O método coloca em um **gráfico**: k **versus** **variação intracluster** (inércia ou SSE).



Contornando algumas deficiências do k-Médias (7/8)

Encontrando um bom valor de k – método do cotovelo


- Espera-se que a homogeneidade dentro dos clusters aumente à medida que clusters vão sendo adicionados.
- O valor ideal de k segue o **princípio da parcimônia**: onde está a **menor variação** possível com a **menor quantidade de clusters significativos**
- “Ponto de cotovelo”:
 - Não existe um ganho significativo em termos de redução da variação.
 - Assim, o melhor k seria exatamente onde o **cotovelo** estaria.
 - Nesse exemplo, **$k = 4$**



Contornando algumas deficiências do k-Médias (8/8)

Exemplo

- $k = 1$, inércia = ~ 2000
 - $k = 2$, cai para 1000
 - $k = 3$, cai para ~ 300
 - $k = 4$, cai para ~ 100
 - $k = 5$ em diante: inércia continua ~ 100
-
- Assim, escolhe-se $k = 4$ como **ponto de cotovelo**, o k ideal.
 - Houve um ganho significativo quando comparado com $k = 3$ e não há ganho para $k = 5$.



Problemas da Inertia (e do k-Médias) (1/6)

Inertia – problemas

- **Assume** que os clusters tem **forma convexa**
 - *Você pode desenhar uma linha reta de qualquer ponto do cluster para qualquer outro de seus pontos sem sair dele.*
- **Assume** que os clusters são **isotrópicos**.
 - *Cada cluster possui aproximadamente o mesmo número de pontos em qualquer direção a partir do centróide.*
 - Isso é: assume que os clusters tem **formato esférico**.


Se o seu problema tem essas características, o ideal é utilizar um **algoritmo de outra família** que **não seja** a dos algoritmos **de particionamento** (ex.: métodos de densidade ou os probabilísticos).

Outros problemas do k-Médias: é sensível a outliers e sofre com a maldição da dimensionalidade (mas esses são tratáveis)

Problemas da Inertia (e do k-Médias) (2/6)

Inertia – problemas

- Na figura, o k está correto ($k=3$), mas os clusters não são isotrópicos (*são alongados e não esféricos*).



Fonte: Scikit-Learn (2026)

Problemas da Inertia (e do k-Médias) (3/6)

- **Tratando o Problema da Maldição da Dimensionalidade.**
 - A inércia **não** é uma medida **normalizada**: sabemos apenas que valores mais baixos são melhores.
 - Em espaços de alta dimensionalidade, as distâncias euclidianas tendem a aumentar (“maldição da dimensionalidade”).
- **Como atenuar ?**
 - Realizando tarefas de pré-processamento, tais como:
 - Seleção de atributos (identificar os mais importantes)
 - Redução da dimensionalidade (ex.: usar PCA).
 - Tratamento de outliers e anomalias.

Problemas da Inertia (e do k-Médias) (4/6)

- Problema (destacando) – Efeito dos Outliers
 - O k-Means é particularmente sensível a outliers.
 - Um outlier está distante da maioria dos outros dados.
 - Quando é associado a um cluster, ele distorce muito o valor médio (centróide).
 - Isso afeta a atribuição de outros objetos ao cluster.
 - E o **efeito** é **exacerbado** pelo uso da função da **soma dos erros quadrados**.
 - Veja o exemplo do slide a seguir.

Problemas da Inertia (e do k-Médias) (5/6)

- **Outliers – Exemplo** (Han et al. 2023)
 - Sejam os pontos no espaço 1D:
 - $\{1, 2, 3, 8, 9, 10, 25\}$.
 - Intuitivamente, os dividiríamos nos clusters:
 - $C_1 = \{1, 2, 3\}$
 - $C_2 = \{8, 9, 10\}$
 - Já o ponto 25
 - Seria ignorado (outlier);
 - ou colocado sozinho em C_3 ;
 - ou acrescentado a C_2 .

Problemas da Inertia (e do k-Médias) (6/6)

- **Outliers – Exemplo** (Han et al. 2011)

- Porém, se rodarmos o k-Means com $k = 2$, temos:

- **Inércia** de $C_1 = \{1, 2, 3\}$ (média=2)
 $C_2 = \{8, 9, 10, 25\}$ (média=13)

$$\text{Inércia} = (1-2)^2 + (2-2)^2 + (3-2)^2 + (8-13)^2 + (9-13)^2 + (10-13)^2 + (25-13)^2 = \underline{196}$$

- **Inércia** de $C_1 = \{1, 2, 3, 8\}$ (média=3.5)
 $C_2 = \{9, 10, 25\}$ (média=14.67)

$$\text{Inércia} = (1-3.5)^2 + (2-3.5)^2 + (3-3.5)^2 + (8-3.5)^2 + (9-14.67)^2 + (10-14.67)^2 + (25-14.67)^2 = \underline{189.67}$$

- O segundo particionamento resulta em menor inércia.
- Sendo assim, o k-Means associaria o ponto **8** a um **cluster diferente** dos pontos **9** e **10**.

Avaliação de Processos de Clustering (1/14)

- Como avaliar ?
 - Para conduzir um processo de *clustering*, precisamos apenas de:
 1. Uma base de dados contendo objetos descritos por um conjunto de *features* (variáveis) X;
 2. Um algoritmo de *clustering*.
 - Porém, da mesma forma que ocorre na classificação:
 - É preciso tentar **avaliar a efetividade** do processo.
 - Ou seja, tentar medir a “**coerência**” dos grupos gerados.
 - Se eles aparentarem coerência, é maior a chance de que sejam grupos bons.


Avaliação de Processos de Clustering (2/14)

- Como avaliar ?
 - Mas diferente do que ocorre na classificação:
 - Os algoritmos de *clustering* **não produzem** exatamente um modelo.
 - E em grande parte das situações práticas, **não temos o “gabarito”*** isto é o cluster certo de cada ponto.
 - Assim, o que é feito na prática é tentar **avaliar qualidade dos clusters** gerados realizando a **comparação** entre eles.
 - Vamos apresentar 2 métodos distintos para isso.

* Se tivermos o gabarito, aí dá até para computar acurácia, construir matriz de confusão etc.

Avaliação de Processos de Clustering (3/14)

- Método 1: Avaliação por Estatística Descritiva
 - Simples e muito usada na avaliação preliminar da qualidade dos clusters
 - Pode ajudar os usuários a entender o perfil (significado) do clusters.
 - **Desvantagem:** inviável se a base de dados possui muitos atributos (dezenas, centenas ou até milhares)




Fonte: <https://www.sqlshack.com/microsoft-clustering-in-sql-server/>

Avaliação de Processos de Clustering (4/14)

- Método 2: Coeficiente de Silhueta

- Examina:
 - O quão bem os clusters estão **separados**
 - O quão **compactos** eles são.
- Baseada nos conceitos de:
 - **Distância intra-cluster**
(entre pontos de um mesmo cluster)
 - **Distância inter-cluster**
(entre pontos de clusters diferentes)



Avaliação de Processos de Clustering (5/14)

- Método 2: Coeficiente de Silhueta

- Após a definição dos clusters, o valor do Coeficiente de Silhueta **para um dado ponto p** pode ser calculado através da seguinte fórmula:

- $s(p) = (b(p) - a(p)) \div \max(a(p), b(p))$

- Mas...

- Qual o significado de **a** e **b** nestas fórmulas e como eles são calculados?
 - Qual é o valor ideal para esse coeficiente?
 - Como calcular o valor final do Coeficiente de Silhueta (a fórmula acima é para um ponto p)?

Avaliação de Processos de Clustering (6/14)

- Como calcular $a(p)$?
 - $s(p) = (b(p) - a(p)) \div \max(a(p), b(p))$
 - Para cada objeto p , devemos calcular $a(p)$ como a média da distância entre p e todos os outros objetos do cluster ao qual ele pertence (**distância intra-cluster**):

$$a(p) = \frac{\sum_{p' \in C_i, p \neq p'} \text{dist}(p, p')}{|C_i| - 1}$$

- Reflete o **quão compacto** é o cluster ao qual p pertence.
 - Quanto menor o valor de $a(p)$, mais compacto, portanto melhor.
- Obs.: *Há outras formas de calcular a distância intra-cluster.*

Avaliação de Processos de Clustering (7/14)

- Como calcular $b(p)$?

- $s(p) = (b(p) - a(p)) \div \max(a(p), b(p))$
- $b(p)$ é a distância média mínima de p para todos os clusters dos quais p não faz parte (**distância inter-cluster**).
- Calculado através da fórmula a seguir, considerando que $p \in C_i$

$$b(p) = \min_{C_j: 1 \leq j \leq k, j \neq i} \left\{ \frac{\sum_{p' \in C_j} \text{dist}(p, p')}{|C_j|} \right\}$$

- Reflete o quão p **está separado** dos outros clusters.
 - Quanto maior o valor de $b(p)$, mais separado, portanto melhor.
- Obs.: *Há outras formas de calcular a distância inter-cluster.*

Avaliação de Processos de Clustering (8/14)


- Qual o valor ideal para $s(p)$?
 - $s(p) = (b(p) - a(p)) \div \max(a(p), b(p))$
- O valor resultante de $s(p)$ estará na faixa entre -1 e 1.
 - Se $s(p) \approx 1$: cluster que contém p é compacto e p está distante dos outros clusters (situação ideal).
 - Se $s(p) < 0$ (ou seja: se $b(p) < a(p)$): p está mais próximo dos objetos de outros cluster do que de seu cluster (situação ruim)

Avaliação de Processos de Clustering (9/14)

- Como calcular o valor final do Coeficiente de Silhueta ?
 - **$s(C_i)$** – Coeficiente de Silhueta do cluster C_i ,
 - Computa-se o valor médio deste coeficiente para todos os pontos que pertençam a C_i .
 - **s** – Coeficiente de Silhueta do Processo de Clustering
 - Computa-se a média do Coeficiente de Silhueta de todos os pontos da base de dados.
 - Visa Indicar a qualidade do processo como um todo.


Avaliação de Processos de Clustering (10/14)

- Exemplo: Silhueta do ponto $p = (8,2)$



Avaliação de Processos de Clustering (11/14)

- Exemplo: Silhueta do ponto $p = (8,2)$



$$a(p) = \frac{\sum_{p' \in C_i, p \neq p'} \text{dist}(p, p')}{|C_i| - 1}$$

$$\text{DE}((9, 4), (8, 2)) = 1.7320508075688772$$


$$\text{DE}((9, 5), (8, 2)) = 2.0$$

$$\text{DE}((7, 3), (8, 2)) = 1.4142135623730951$$

$$a(p) = (1.73 + 2.0 + 1.41) / 3 = \underline{1.72}$$

Avaliação de Processos de Clustering (12/14)

- Exemplo: Silhueta do ponto $p = (8,2)$



$$b(p) = \min_{C_j: 1 \leq j \leq k, j \neq i} \left\{ \frac{\sum_{p' \in C_j} \text{dist}(p, p')}{|C_j|} \right\}$$

Dist. p/ pontos de **C1**:

$\text{DE}((1, 8), (8, 2)) = 7.416198487095663$
 $\text{DE}((3, 9), (8, 2)) = 5.656854249492381$
 $\text{DE}((4, 7), (8, 2)) = 4.58257569495584$
 $\text{DE}((9, 9), (8, 2)) = 2.8284271247461903$
média = 5.12


Dist. p/ pontos de **C2**:

$\text{DE}((1, 1), (8, 2)) = 6.928203230275509$
 $\text{DE}((2, 3), (8, 2)) = 6.082762530298219$
 $\text{DE}((2, 6), (8, 2)) = 6.324555320336759$
 $\text{DE}((3, 5), (8, 2)) = 5.291502622129181$
 $\text{DE}((4, 3), (8, 2)) = 4.123105625617661$
média = 5.75

$b(p) = \min(5.12, 5.75) = \underline{5.12}$

Avaliação de Processos de Clustering (13/14)

- Exemplo: Silhueta do ponto $p = (8,2)$



- Valor final:

$$s(p) = (b(p) - a(p)) \div \max(a(p), b(p)) = (5.12 - 1.72) \div \max(1.72, 5.12) = \underline{0.67}$$

Avaliação de Processos de Clustering (14/14)

- **Silhueta – prós e contras**
 - A medida da silhueta é mais **adequada** para:
 - Algoritmos de **Particionamento** e **Hierárquicos**.
 - Já que eles trabalham distância entre pontos
 - E é totalmente **inadequada** para **Algoritmos de Densidade**.
 - Outras medidas conhecidas:
 - **Índice de Dunn**
 - **Índice de Calinski-Harabasz**
 - Também usadas para clustering por Particionamento e Hierárquico.

Principais conceitos apresentados

- **Clustering:** Processo em que um algoritmo é empregado para dividir automaticamente um conjunto de objetos em grupos (*clusters*) de acordo com algum relacionamento de similaridade entre os objetos. Também chamado de análise de agrupamentos, clusterização, segmentação de dados, entre outros nomes.
- **Similaridade intra-cluster:** valor que indica a similaridade entre objetos pertencentes a um mesmo cluster. Em um bom modelo, espera-se que seja alta.
- **Similaridade inter-cluster:** valor que indica a similaridade entre objetos pertencentes a clusters diferentes. Em um bom modelo, espera-se que seja baixa.
- **Problema de aprendizado supervisionado:** problema em que o algoritmo constrói um modelo a partir de uma base de dados de treinamento em que os objetos são pares (*features* X; variável alvo y). O objetivo do algoritmo será criar uma função de mapeamento $y = f(X)$. Exemplo: Classificação
- **Problema de aprendizado não supervisionado:** problema em que o algoritmo explora uma base de dados contendo apenas as *features* X dos objetos (não existe a variável y) Assim, o algoritmo deve descobrir por si só os possíveis relacionamentos entre os objetos. Exemplo: Clustering.
- **k-Médias (*k-Means*):** um dos mais famosos algoritmos de clustering, pertencente à família dos métodos de particionamento. Outros exemplos de algoritmos famosos são: hierárquico aglomerativo, k-Medoids, k-Modes, Expectation-Maximization, DBScan, Self-organizing maps, entre outros.
- **Centróide:** ponto que representa o centro de um dado cluster.
- **Método do cotovelo:** método para identificação automática do valor ideal de k (número de clusters)
- **SSE ou Inertia:** soma do erro quadrado intra-cluster, valor que o k-Médias tenta minimizar.
- **Cluster esférico (ou isotrópico):** cluster que possui aproximadamente o mesmo número de pontos em qualquer direção a partir do centróide. O k-Médias produz clusters com essa característica.
- **Coeficiente de silhueta:** medida que pode ser utilizada para avaliar o processo de análise de agrupamentos adequada para problemas em que os clusters são esféricos.

Referências

- CARVALHO, M. S.; CRUZ, O. G.; NOBRE, F. F. Perfil de risco: método multivariado de classificação sócio-econômica de microáreas urbanas – os setores censitários da região metropolitana do Rio de Janeiro. **Cad. Saúde Publ**, Rio de Janeiro, v. 13(4), p. 635-645, 1997.
- HAN, J.; PEI, J.; TONG, H. Cluster analysis: Basic concepts and methods. *In*: HAN, J.; PEI, J.; TONG, H. **Data Mining: Concepts and Techniques**. 4. ed. Waltham: Morgan Kauffman, 2023. cap 8, p. 379 – 394.
- HUANG, Z. Extensions to the k-Means algorithm for clustering large data sets with categorical values. **Data Mining and Knowledge Discovery**, Dordrecht, v. 2, p. 283–304, 1998.
- SCIKIT-LEARN. k-Means. 2026. Disponível em: <<https://scikit-learn.org/stable/modules/clustering.html#k-means>>. Acesso em: 8 mai. 2026.
- SOARES, S. S. R. F, Metaheurísticas para o problema da clusterização automática. 2004. 137 f. Dissertação (Mestrado em Ciência da Computação) – Instituto de Computação, Universidade Federal Fluminense, Niterói, 2004.