

Modelagem de Tópicos com o algoritmo LDA

Aula 10 – Inteligência Computacional

Eduardo Corrêa Gonçalves

09/09/2026

Sumário

Introdução

O que é Modelagem de Tópicos ?

Algoritmo LDA (*Latent Dirichlet Allocation*)


Muito prazer, LDA

Geração do modelo: algoritmo em um exemplo passo a passo

Introdução (1/3)

O que é modelagem de tópicos (*topic modeling*) ?


- Consiste na tarefa de **dividir automaticamente** uma coleção de **textos em grupos**, de acordo com a **similaridade entre os tópicos** abordados.



Introdução (2/3)

Tarefa não supervisionada

- A modelagem de tópicos é uma **tarefa não supervisionada**. Pode ser vista como um processo de **clustering** para textos.
- Nós não sabemos os tópicos de antemão. Só temos os textos.
- O algoritmo aloca os textos em diferentes grupos de acordo com a similaridade dos assuntos (tópicos).
- Os **k grupos** descobertos são denotados por **tópico₁, tópico₂, ..., tópico_k**.



Introdução (3/3)


Algoritmos para modelagem de tópicos

- Os dois algoritmos para modelagem de tópicos mais conhecidos são:
 - **Latent Dirichlet Allocation – LDA** (Blei et al. 2003).
 - método probabilístico / bayesiano (estatística clássica)
 - visão geral: assume que cada documento é uma mistura de tópicos latentes e que cada tópico é caracterizado por uma distribuição sobre palavras.
 - **BERTopic** (Grootendorst 2022).
 - método neural
 - visão geral: emprega embeddings BERT junto com TF-IDF e um algoritmo de *clustering* baseado em densidade (HDBScan) para agrupar os textos
- A **aula de hoje** aborda o algoritmo **LDA**.

Conhecendo o LDA (1/5)

Tópicos Latentes

- A tarefa de modelagem de tópicos **descobre**, automaticamente, os **tópicos latentes** de uma coleção de documentos.
 - **Latentes = Escondidos**
- Isso é feito sem que ninguém diga de antemão quais temas existem e nem rotule qualquer um dos textos.



coleção de documentos
(corpus)

*Não sabemos os
tópicos de antemão.
Só temos os textos.*

Conhecendo o LDA (2/5)

Tópicos são grupos de palavras

- O algoritmo LDA resolve o problema identificando **grupos de palavras** que melhor caracterizam a informação dos documentos.
- Ao final, o LDA terá identificado **k grupos** (sendo k definido pelo usuário)
- Cada grupo representará um **tópico**.
- Exemplo: {filme, gramado, diretor, atriz, ator, prêmio}
 - Ao analisar as palavras desse grupo, o usuário poderá deduzir que o tópico é **festival de cinema de Gramado**

Conhecendo o LDA (3/5)

Vamos analisar um exemplo

- Sejam:
 - o corpus apresentado abaixo;
 - $k = 2$;
- Como seria um **exemplo de possível saída** gerada pelo LDA ?
 - *No próximo slide a resposta... Veremos que a saída terá **2 partes**.*

1	eu trouxe uma barra de chocolate para lanchar
2	eu gosto de comer chocolate, amendoim e castanhas
3	meu vizinho tem 2 cachorros
4	cachorros e gatos são inimigos mortais
5	cachorros não podem comer chocolate

Conhecendo o LDA (4/5)

Entrada: corpus abaixo e $k = 2$

1	eu trouxe uma barra de chocolate para lanche
2	eu gosto de comer chocolate, amendoim e castanhas
3	meu vizinho tem 2 cachorros e 1 gato
4	cachorros e gatos são inimigos mortais
5	cachorros não podem comer chocolate

Saída:

- **Tópico 1:** 30% chocolate, 15% amendoim, 10% lanche...
- *Podemos interpretar que esse tópico trata de **alimentação**.*
- **Tópico 2:** 35% cachorros, 15% gatos, 5% chocolate...
- *Já esse tópico parece tratar principalmente de **animais**.*

PARTE 1:
tópicos
identificados

- Docs. 1 e 2: 100% Tópico 1
- Docs. 3 e 4: 100% Tópico 2
- Doc 5: 60% Tópico 1, 40% Tópico 2

PARTE 2:
% de cada tópico
em cada
documento

Conhecendo o LDA (5/5)

Não esqueça! A saída do LDA tem 2 partes:

- **PARTE 1: os k tópicos:**
 - Grupos de palavras que tendem a aparecer juntas em certos documentos.
 - Um tópico é apresentado pelas suas palavras mais representativas e **cabe ao analista interpretar** e atribuir um título.
 - Ex.: Tópico 1: {30% *chocolate*, 15% *amendoim*, 10% *lanche*}.
 - analista humano pode inferir que o tópico é **alimentação**;
 - **chocolate** é a palavra mais representativa do tópico.
- **PARTE 2: o percentual de cada tópico em cada documento:**
 - Um documento não “pertence” necessariamente a um único tópico, ele é uma “mistura”.
 - Ex.: pode ser 60% **alimentação** e 40% **animais**.

LDA – apresentando o exemplo da aula (1/5)

Corpus de Notícias (Serrano, 2020a, 2020b)

- Imagine uma coleção de notícias.
 - algumas sobre **ciência (Science)** ;
 - outras sobre **política (Politics)**;
 - outras sobre **esportes (Sports)**.
 - e certas notícias sobre 2 tópicos ao mesmo tempo



Science



Politics



Science



Sports



Sports



Science
Politics




Sports
Science

LDA – apresentando o exemplo da aula (2/5)

Corpus de Notícias

- Para simplificar, suponha essa coleção possui apenas **4 documentos**, todos com **5 palavras**.
- E que o vocabulário (V) é composto apenas pelas seguintes palavras:
 - $V = \{\text{"ball", "planet", "galaxy", "referendum"}\}$ (*vamos supor que só essas 4 são permitidas*).




- Como mencionado, há **3 tópicos latentes**: Science, Politics, Sports.

LDA – apresentando o exemplo da aula (3/5)

Corpus de Notícias

- Obviamente as notícias não fazem sentido.
- Porém, de fato, o LDA “vê” os textos dessa forma... como um saco de palavras (*bag of words*).



LDA – apresentando o exemplo da aula (4/5)

Exercício :

Que tópicos você associaria para cada documento?


The diagram shows four documents, each represented by a clipboard icon. Below each document is a topic label in a specific color: Science (blue), Politics (green), and Sports (red). The topics are associated with the documents as follows: Doc 1 is associated with Science; Doc 2 and Doc 3 are associated with Politics; and Doc 4 is associated with Sports.

Document	Words	Topic
Doc 1	ball ball ball planet galaxy	Science
Doc 2	referendum planet planet referendum referendum	Politics
Doc 3	planet planet galaxy planet ball	Politics
Doc 4	planet galaxy referendum planet ball	Sports

LDA – apresentando o exemplo da aula (5/5)

Possível reposta

- **Doc1** tem “ball” 3x, e “galaxy” 1x (que poderia se referir ao time LA Galaxy) → **Sports**
- **Doc2** tem “referendum” 3x e “planet” 2x → **Politics**
- **Doc3** tem “planet” 3x e “galaxy” → **Science**
- **Doc4** parece mais ambíguo. Mas ele tem “planet” 2x e “galaxy” então vamos dizer que é → **Science**... Mas poderia ser **Science** e **Politics**...



LDA – Exemplo x Realidade (1/2)

O LDA não sabe nada de semântica (1/2)

- Nós resolvemos o problema sabendo os tópicos de antemão
- E sabendo o que as palavras significam
- Mas o **LDA** é um **método estatístico** que não sabe o que elas significam*
 - É como se fossemos resolver o problema em Quíchua (língua indígena da América do Sul)




*Ao contrário do BERTopic e de métodos baseados em LLMs que incorporam informação semântica para modelar tópicos

LDA – Exemplo x Realidade (2/2)

O LDA não sabe nada de semântica (2/2)

- O LDA não sabe que as palavras “planet” e “galaxy” são relacionadas semanticamente.
- Ele só sabe:
 - Quantas vezes elas aparecem em um mesmo documento
 - Quantas vezes aparecem separadamente. Etc.
- Também não sabe definições de tópicos. Só sabe rotular como **tópico 1**, **tópico 2**, **tópico 3**.



LDA – recapitulando... (1/3)


Antes de apresentar o algoritmo do LDA, vamos relembrar que:

- Para gerar o modelo, o LDA assume que:
 - Cada **documento** é uma **mistura de alguns tópicos**.
 - **Ex.:** um texto sobre **economia**, tem **70% de vocabulário financeiro** e **30% político**.
 - Cada **tópico** é uma **mistura de várias palavras**.
 - **Ex.:** o tópico **esporte** tem alta chance para “**bola**”, “**gol**”, “**estádio**”.
 - Cada **documento** é um “**saco de palavras**” (*bag of words*).
 - A ordem das palavras no texto não importa, apenas sua frequência.
 - **Ex.:** “**olá, meu amigo, olá!**” → { “**amigo**”: 1, “**meu**”: 1, “**olá**”: 2 }

LDA – recapitulando... (2/3)

O que o LDA vai fazer?


- O usuário escolhe k (quantos tópicos deseja). Nesse exemplo, $k = 3$
 - Suponha que cada tópico tem 1 cor: **tópico 1**, **tópico 2**, **tópico 3**
- Ao final do processamento, o LDA terá atribuído um tópico para cada palavra de cada documento.
 - Se uma palavra aparece muitas vezes, ela pode receber diferentes tópicos
 - Ao final, cada documento será a mistura de alguns tópicos.
- Abaixo, um exemplo de solução plausível:



LDA – recapitulando... (3/3)

Descrevendo a solução plausível


- Cada palavra foi colorida com uma das 3 cores de tópico.
- Assim é possível ver quantas vezes uma cor aparece em um documento e dar a ele essa cor
 - **Doc. 1:** 4 palavras **vermelhas** e 1 **azul** → ele é **80% tópico 3** e **20% tópico 1**
- De maneira análoga:
 - **Doc. 2** → **80% tópico 2** e **20% tópico 1**
 - **Doc. 3** → **80% tópico 1** e **20% tópico 3**
 - **Doc. 4** → **60% tópico 1**, **20% tópico 2** e **20% tópico 3**



LDA – Propriedades Desejadas

Quais propriedades o LDA considera boas para as cores?

- **P1:** palavras devem ser quão **monocromáticas** quanto for possível
- **P2:** docs devem ser o quão **monocromáticos** quanto for possível
- **Intuição:** veja a palavra “**galaxy**”. Aparece 3 vezes, 2 delas em azul.
 - De fato, no mundo real, na maioria das vezes está associada à **ciência**.
 - Por isso, o LDA tenta deixar cada palavra com poucas cores diferentes.
 - Da mesma forma, tenta deixar os docs. com 1 tópico predominante.



LDA – algoritmo passo a passo (1/13)

Amostragem de Gibbs

- O LDA é um método matemático para estimar ao mesmo tempo:
 - A mistura de palavras associadas a um tópico.
 - A mistura de tópicos que descreve um documento.
- O **método exato** para calcular essas estimativas é **intratável**, pois exigiria o cálculo de um número imenso de combinações.
 - Detalhes sobre a fundamentação teórica podem ser obtidos na videoaula de (Serrano, 2020a). *Algumas informações eu coloquei no ANEXO desse PPT.*
- Por isso, na prática se adota uma solução heurística, baseada em **amostragem de Gibbs** (*Gibbs Sampling*).
- Vamos explicar o processo seguindo com o exemplo originalmente disponibilizado em (Serrano, 2020b).

LDA – algoritmo passo a passo (2/13)

PASSO 1: cada palavra é iniciada com cores (tópicos) aleatórias entre as k disponíveis.

- Essas cores serão melhoradas processando uma palavra por vez
- E fazendo esse processo repetidas vezes



LDA – algoritmo passo a passo (3/13)

PASSO 2: Colorindo as palavras

- A 1ª palavra do 1º doc. é selecionada. Ela está colorida de verde
- Mas **isso será esquecido** o algoritmo tentará encontrar a melhor cor para a palavra.
 - Para tal, ele assume que todas as outras palavras estão coloridas corretamente (mesmo que ainda não estejam).
 - Considerando essa suposição, que cor que deve ser atribuída a palavra “*ball*” selecionada?



LDA – algoritmo passo a passo (4/13)

PASSO 2(a): Colorindo as palavras – tópicos do documento

- Inicialmente, os outros docs são esquecidos. Apenas o documento da palavra selecionada é considerado.
- Faz sentido dar à palavra selecionada uma cor que seja prevalente no documento
 - Quantas palavras **azuis** há no Doc1 ? = 2 $\rightarrow P(\text{tópico 1} \mid \text{Doc1}) = 2/4$
 - Quantas **verdes** ? = 0. $\rightarrow P(\text{tópico 2} \mid \text{Doc1}) = 0/4$
 - Quantas **vermelhas** ? = 2. $\rightarrow P(\text{tópico 3} \mid \text{Doc1}) = 2/4$
- Faz sentido dar a cor **azul** ou **vermelha**. Mas qual?
 - Vamos quebrar esse empate observando “*ball*” nos demais documentos



LDA – algoritmo passo a passo (5/13)

PASSO 2(b): Colorindo as palavras – tópicos da palavra


- Agora vamos olhar como “ball” está colorida em todos os documentos.
 - “ball” em azul = 0 $\rightarrow P(\text{“ball”} \mid \text{Tópico 1}) = 0/4$
 - “ball” em verde = 1 $\rightarrow P(\text{“ball”} \mid \text{Tópico 2}) = 1/4$
 - ball” em vermelho = 3 $\rightarrow P(\text{“ball”} \mid \text{Tópico 2}) = 3/4$



LDA – algoritmo passo a passo (6/13)

PASSO 2(c): associando probabilidades para cada tópico

- Vamos pintar essa palavra “ball” (palavra selecionada) com probabilidade proporcional ao resultado de:
 - $P(\text{tópico } t \mid \text{Doc.1}) \times P(\text{palavra “ball”} \mid \text{tópico } t) \quad \text{para } t = \{1, 2, 3\}$
- Para evitar que alguns resultados deem 0, serão adicionados valores de constantes α e β aos termos.



LDA – algoritmo passo a passo (7/13)

PASSO 2(c): associando probabilidades para cada tópico

- Vamos supor α e $\beta = 0,1$. Uma possível forma de calcular é*:
- $P(\text{ball}_1 = \text{"azul"}) = P(\text{tóp. azul} \mid \text{Doc.1}) \times P(\text{palavra "ball"} \mid \text{tóp. azul}) =$
 - $(2+\alpha) / 4 \times (0+\beta) / 4 = 0,0131$
- $P(\text{ball}_1 = \text{"verde"}) = P(\text{tóp. verde} \mid \text{Doc.1}) \times P(\text{palavra "ball"} \mid \text{tóp. verde}) =$
 - $(0+\alpha) / 4 \times (1+\beta) / 4 = 0,0069$
- $P(\text{ball}_1 = \text{"vermelho"}) = P(\text{tóp. vermelho} \mid \text{Doc.1}) \times P(\text{palavra "ball"} \mid \text{tóp. vermelho}) =$
 - $(2+\alpha) / 4 \times (3+\beta) / 4 = 0,4069$

Topic 1	Topic 2	Topic 3
How much is Topic 1 in Doc 1?	How much is Topic 2 in Doc 1?	How much is Topic 3 in Doc 1?
$2 + \alpha$	$0 + \alpha$	$2 + \alpha$
How much is 'ball' in Topic 1?	How much is 'ball' in Topic 2?	How much is 'ball' in Topic 3?
$0 + \beta$	$1 + \beta$	$3 + \beta$




*** **ATENÇÃO:** Exemplo ilustrativo, apenas para passar a ideia. O cálculo não é feito exatamente dessa forma.

LDA – algoritmo passo a passo (8/13)

PASSO 2(d): finalmente, daremos uma cor para a “ball” do Doc1

- Mas ela não será imediatamente pintada de vermelho (maior probabilidade calculada)
 - Na verdade, chance será dada a todas as cores
 - A escolha será feita de forma proporcional à probabilidade de cada tópico.



LDA – algoritmo passo a passo (9/13)

PASSOS seguintes


- Vamos supor que a 1ª palavra do 1º documento (*ball*) ficou colorida de **vermelho** (que era a maior probabilidade)
- Assim, o documento ficou mais monocromático porque de **verde** (cor original) ela passou para **vermelho** (nova cor)
- A palavra *ball* também ficou mais monocromática nos documentos como um todo;
- Com maior probabilidade, foi produzido um esquema de cores melhor



LDA – algoritmo passo a passo (10/13)

PASSOS seguintes


- Se repetirmos esse passo muitas vezes (agora para a próxima *ball*), recolorindo todas as palavras do corpus, a expectativa é que obteremos uma solução melhor no final.
- Fazemos muitos loops no corpus, até que as mudanças se estabilizem



LDA – algoritmo passo a passo (11/13)

Como obter os tópicos de cada documento?


- Basta olhar para a maioria
- Doc1 é 80% vermelho e 20% azul



LDA – algoritmo passo a passo (12/13)

Como definir os tópicos ?

- Veja que o **Tópico 1** é planet (7) e galaxy (2).
 - Ou seja: **77% planet, 23% galaxy**
 - O analista humano poderá inferir que significa **Ciência**.
- Na prática, costuma-se fazer a análise observando as d palavras mais populares de cada um dos k tópicos (ex.: 10 ou 20 mais populares)



LDA – algoritmo passo a passo (13/13)

IMPORTANTE: associando probabilidades para cada tópico

- O slide que mostrou o cálculo das probabilidades apresentou apenas um exemplo ilustrativo.
 - O cálculo real não é feito do jeito mostrado.
 - Por exemplo, vamos ver como a sklearn faz;
- Retomando o exemplo de $P(\text{ball}_1 = \text{"azul"})$ (prob. da 1ª palavra "ball" do 1º doc. ser do **tópico azul**), a sklearn computaria da seguinte forma:

$$(\text{tot. pal. t\u00f3p. azul no Doc1} + \alpha) \times (\text{tot. de pal. "ball" no t\u00f3p. azul} + \beta)$$

$$\text{tot. geral pal. t\u00f3pico azul} + |V| \times \beta$$

Comentários Finais

Como o valor de k pode ser escolhido ?

- Pode-se utilizar uma medida chamada “coerência vetorial” ou “coerência c_v ”. Mas há outras.

Como a qualidade do processo pode ser avaliada ?

- Em geral, utiliza-se uma medida chamada de “Perplexidade”.
- Ou com a própria coerência vetorial.

Referências

- BLEI, David M.; NG, Andrew Y.; JORDAN, Michael I. Latent Dirichlet Allocation. Journal of Machine Learning Research, v. 3, p. 993-1022, Jan. 2003
- NAIR, G. **Text Mining 101: Topic Modeling**. [S.l.]: KDNuggets, 2016. Disponível em < <https://www.kdnuggets.com/2016/07/text-mining-101-topic-modeling.html> >. Acesso em: 11 set. 2026.
- SERRANO, L. **Latent Dirichlet Allocation (Part 1 of 2)**. [S.l.]: YouTube, 2020. 1 video (26 min. 55 seg.). Disponível em < <https://www.youtube.com/watch?v=T05t-SqKArY> >. Acesso em: 03 set. 2026.
- SERRANO, L. **Training Latent Dirichlet Allocation: Gibbs Sampling (Part 2 of 2)**. [S.l.]: YouTube, 2020. 1 video (26 min. 30 seg.). Disponível em < https://www.youtube.com/watch?v=BaM1uiCpj_E >. Acesso em: 03 set. 2026.
- SILGE, J.; ROBINSON, D. Topic Modeling. *In*: SILGE, J.; ROBINSON, D. **Text Mining with R: A Tidy Approach**. [S.l.]: O'Reilly, 2017. cap 6, p. 85 – 104.

ANEXO – um pouco de fundamentação teórica (1/6)

LDA – Latent Dirichlet Allocation

- Proposto em Blei et al. (2003), o algoritmo LDA ataca o problema da modelagem de tópicos como um problema generativo que visa responder a seguinte pergunta:
 - “Qual a estrutura escondida que provavelmente gerou a coleção de documentos do corpus?”

ANEXO – um pouco de fundamentação teórica (2/6)

A Famosa Equação do LDA

- Não iremos apresentar detalhes sobre a fundamentação teórica do algoritmo.
 - Se você se interessar pelo tema, recomendamos como um bom ponto de partida a videoaula de Serrano (2020a).
- Apenas citaremos que o que o LDA procura **maximizar a equação** abaixo, considerando todos os documentos do corpus.
 - Nessa equação, os dois primeiros termos representam **Distribuições de Dirichlet** (daí o nome do algoritmo).

Probability of a document

$$P(W, Z, \theta, \varphi; \alpha, \beta) = \prod_{j=1}^M P(\theta_j; \alpha) \prod_{i=1}^K P(\varphi_i; \beta) \prod_{t=1}^N P(Z_{j,t} | \theta_j) P(W_{j,t} | \varphi_{Z_{j,t}})$$




Topics



Words



Topics




Words

ANEXO – um pouco de fundamentação teórica (3/6)

Intuição – Para facilitar, podemos pensar em uma abordagem geométrica.


- Se temos 3 tópicos, o LDA constrói um triângulo em que os vértices são os tópicos.
- Então coloca os documentos dentro desse triângulo de uma forma que os documentos ficarão próximos do tópico ao qual pertencam.
- O objetivo da primeira Distribuição de Dirichlet da equação do slide anterior é exatamente obter a melhor arrumação de documentos nos tópicos.



ANEXO – um pouco de fundamentação teórica (4/6)

Intuição – continuando com a abordagem geométrica.

- Além disso, temos um tetraedro em que os vértices são palavras e os pontos são tópicos.




- O objetivo da segunda Distribuição de Dirichlet é encontrar a melhor arrumação dos pontos (tópicos) nesse tetraedro.

ANEXO – um pouco de fundamentação teórica (5/6)

Gerando Documentos

- Cada Distribuição de Dirichlet gera uma Distribuição Multinomial.
- Assim, pode-se gerar um documento.



ANEXO – um pouco de fundamentação teórica (6/6)

Quais os melhores parâmetros?

- O ideal seria testar todas as possíveis configurações de parâmetros para as Distribuições de Dirichlet e escolher a melhor delas.
 - Isso é:** aquela que consegue reproduzir como maior probabilidade a distribuição dos documentos originais.
- Entretanto, essa **abordagem** é **intratável** devido ao número explosivo de combinações.
 - Solução:** usar uma heurística... A mais usada: Gibbs Sampling.

